

**CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA
CELSO SUCKOW DA FONSECA**

**COORDENAÇÃO DO CURSO DE BACHARELADO EM
CIÊNCIA DA COMPUTAÇÃO**

NOEMI CHO DE ALMEIDA

**INTEGRAÇÃO DE RADAR METEOROLÓGICO E ESTAÇÕES
DE SUPERFÍCIE PARA PREVISÃO DE PRECIPITAÇÃO NO
RIO DE JANEIRO COM TÉCNICAS DE APRENDIZADO DE
MÁQUINA**

TRABALHO DE CONCLUSÃO DE CURSO

RIO DE JANEIRO

2026

NOEMI CHO DE ALMEIDA

**INTEGRAÇÃO DE RADAR METEOROLÓGICO E ESTAÇÕES
DE SUPERFÍCIE PARA PREVISÃO DE PRECIPITAÇÃO NO
RIO DE JANEIRO COM TÉCNICAS DE APRENDIZADO DE
MÁQUINA**

Trabalho de Conclusão de Curso apresentado
como requisito parcial à obtenção do título
de Bacharel em Ciência da Computação, da
Coordenação do curso de Bacharelado em
Ciência da Computação, do Centro Federal
de Educação Tecnológica Celso Suckow da
Fonseca.

Orientador: Eduardo Bezerra, D.Sc.

Coorientadora: Rafaela Castro, M.Sc.

RIO DE JANEIRO

2026

Ficha catalográfica elaborada pela Biblioteca Central do CEFET/RJ

A ficha catalográfica contém as informações fundamentais para a identificação do TCC no sistema da biblioteca. Ela contém informações do TCC como autor, título, local, assunto, tamanho, número de páginas, tipo de trabalho científico, instituição, ano e palavras-chave.

Após a apresentação do TCC e de ter efetuado todas as correções com a anuência do(a) orientador(a), deve-se enviar a solicitação de ficha catalográfica para:

bcficha.maracana@cefet-rj.br

anexando o trabalho de conclusão de curso. O prazo de entrega da ficha é de até 3 dias úteis.

Obtida a ficha, substitua o arquivo ficha.pdf pela recebida da biblioteca para incluir na seu texto.

Dedico este TCC à minha família e ao meu
namorado, pelo apoio, pela torcida e pela
compreensão nos momentos de dedicação
intensa a este trabalho.

AGRADECIMENTOS

Agradeço imensamente à minha mãe, por todo o apoio e incentivo ao longo desta trajetória, permitindo que eu me dedicasse integralmente a este trabalho, sempre com amor, carinho e compreensão.

Agradeço à minha família pelo suporte e pela torcida durante todo esse processo.

Agradeço ao meu namorado pelo amor, apoio e compreensão, especialmente nos momentos de maior pressão, sempre me tranquilizando e me dando forças para continuar.

Agradeço ao meu orientador pela orientação, paciência, correções e direcionamentos essenciais ao longo do desenvolvimento deste TCC.

Por fim, agradeço a Deus por permitir que esta etapa do trabalho fosse concluída.

TERMO DE APROVAÇÃO

Título: Integração de Radar Meteorológico e Estações de Superfície para Previsão de Precipitação no Rio de Janeiro com Técnicas de Aprendizado de Máquina

Discente(s): Noemi Cho de Almeida

Data de aprovação: _____

Banca Examinadora:

Orientador - Eduardo Bezerra, D.Sc.

Coorientadora - Rafaela Castro, M.Sc.

Membro Interno - Eduardo Ogasawara, D.Sc.

Membro Externo - Raquel Franco, M.Sc.

RESUMO

Noemi Cho de Almeida. **Integração de Radar Meteorológico e Estações de Superfície para Previsão de Precipitação no Rio de Janeiro com Técnicas de Aprendizado de Máquina**. 2026. 67. Trabalho de Conclusão de Curso – Centro Federal de Educação Tecnológica Celso Suckow da Fonseca. Rio de Janeiro, 2026.

A previsão imediata de precipitação (nowcasting) é essencial para reduzir os impactos de eventos de chuva intensa na Região Metropolitana do Rio de Janeiro, onde alagamentos, deslizamentos e inundações representam riscos constantes à população. Radares meteorológicos, como o Radar do Sumaré, fornecem observações contínuas de refletividade com alta resolução espacial e temporal, permitindo acompanhar a formação e o deslocamento de sistemas precipitantes em tempo quase real. Entretanto, a refletividade observada pelo radar não corresponde diretamente à precipitação em superfície, sendo necessária sua integração com dados pluviométricos medidos por estações de superfície. Essa integração é desafiada pelo forte desbalanceamento entre eventos de chuva e não-chuva, pela variabilidade topográfica da região e pela distribuição espacial irregular das estações pluviométricas.

Neste trabalho, propõe-se uma abordagem de previsão espaço-temporal de precipitação baseada na integração entre imagens do Radar Meteorológico do Sumaré e medições pluviométricas do sistema WebSirene. Para lidar com a diferença entre a grade regular do radar e a distribuição pontual das estações, são construídos campos esparsos de precipitação e máscaras de observação, permitindo que o modelo produza estimativas em grade, mas seja avaliado apenas nos pontos onde há medições disponíveis. A arquitetura principal adotada é a Spatiotemporal Convolutional Sequence-to-Sequence (STConvS2S), treinada a partir de sequências de imagens de radar para prever a precipitação em horizontes futuros. Como modelos de referência, são considerados um baseline de persistência e modelos locais baseados em Random Forest Regressor, treinados separadamente para estações de superfície.

A metodologia envolve a organização e sincronização temporal dos dados de radar e pluviômetros, a agregação das imagens de radar para intervalos compatíveis com as medições das estações, a construção dos alvos esparsos com máscara de observação e a avaliação do desempenho por métricas como raiz do erro quadrático médio (RMSE), erro absoluto médio (MAE) e viés. Os resultados são analisados globalmente, por horizonte de previsão e por faixas de intensidade de precipitação, com atenção especial à subestimativa de eventos moderados, fortes e extremos. Espera-se que a abordagem espaço-temporal proposta permita explorar de forma mais adequada a estrutura espacial e a evolução temporal dos sistemas precipitantes, contribuindo para o desenvolvimento de modelos de

nowcasting mais robustos e alinhados às necessidades do projeto RioNowCast.

Palavras-chave: Previsão Meteorológica. Precipitação. Aprendizado de Máquina. Radar. Pluviômetros.

ABSTRACT

Noemi Cho de Almeida. **Integration of Meteorological Radar and Surface Stations for Precipitation Forecasting in Rio de Janeiro Using Machine Learning Techniques**. 2026. 67. Undergraduate Thesis – Federal Center of Technological Education. Rio de Janeiro, 2026.

Precipitation nowcasting is essential to reduce the impacts of intense rainfall events in the Metropolitan Region of Rio de Janeiro, where urban flooding, landslides, and inundations pose constant risks to the population. Weather radars, such as the Sumaré Radar, provide continuous reflectivity observations with high spatial and temporal resolution, allowing the monitoring of the formation and displacement of precipitating systems in near real time. However, radar reflectivity does not directly correspond to surface precipitation, requiring its integration with rainfall measurements obtained from surface stations. This integration is challenging due to the strong imbalance between rain and no-rain events, the region's topographic variability, and the irregular spatial distribution of rain gauge stations. This work proposes a spatiotemporal precipitation forecasting approach based on the integration of images from the Sumaré Weather Radar and rainfall measurements from the WebSirene system. To address the difference between the regular radar grid and the point-based distribution of surface stations, sparse precipitation fields and observation masks are constructed, allowing the model to generate gridded estimates while being evaluated only at locations where measurements are available. The main architecture adopted is the Spatiotemporal Convolutional Sequence-to-Sequence (STConvS2S), trained from sequences of radar images to predict precipitation at future horizons. As reference models, a persistence baseline and local Random Forest Regressor models trained separately for surface stations are considered. The methodology involves the organization and temporal synchronization of radar and rain gauge data, the aggregation of radar images into intervals compatible with station measurements, the construction of sparse targets with observation masks, and performance evaluation using metrics such as root mean squared error (RMSE), mean absolute error (MAE), and bias. The results are analyzed globally, by forecast horizon, and by precipitation intensity ranges, with special attention to the underestimation of moderate, heavy, and extreme rainfall events. The proposed spatiotemporal approach is expected to better exploit the spatial structure and temporal evolution of precipitating systems, contributing to the development of more robust nowcasting models aligned with the needs of the RioNowCast project.

Keywords: Meteorological Forecasting. Precipitation. Machine Learning. Radar. Rain Gauges.

LISTA DE FIGURAS

Figura 2.1 - Ilustração do processo de formação de chuvas convectivas.	6
Figura 2.2 - Ilustração do processo de formação de chuvas frontais.....	7
Figura 2.3 - Ilustração do processo de formação de chuvas orográficas.	8
Figura 2.4 - Geometria da varredura PPI em radares meteorológicos.	10
Figura 2.5 - Esquema de funcionamento do modelo Random Forest para estima- tiva de precipitação.	17
Figura 2.6 - Modelo Digital de Elevação da região do Rio de Janeiro.	18
Figura 4.1 - Fluxo geral da metodologia utilizada para previsão de precipitação... ..	26
Figura 4.2 - Área de cobertura do Radar do Sumaré.	27
Figura 4.3 - Exemplo de imagem do Radar do Sumaré.	28
Figura 5.1 - Distribuição da precipitação observada na estação 14.	38
Figura 5.2 - Distribuição binária da ocorrência de chuva na estação 14.	39
Figura 5.3 - Distribuição dos valores RGB do radar na estação 14.	39
Figura 5.4 - Matriz de correlação entre radar, relevo e precipitação da estação 14.	40
Figura 5.5 - Área de cobertura do Radar Meteorológico do Sumaré.	53
Figura 5.6 - Comparação entre refletividade do radar e precipitação estimada para a Estação 10.	55
Figura 5.7 - Comparação entre refletividade do radar e precipitação estimada para a Estação 11.	56
Figura 5.8 - Comparação entre refletividade do radar e precipitação estimada para a Estação 12.	57
Figura 5.9 - Comparação entre refletividade do radar e precipitação estimada para a Estação 13.	58
Figura 5.10 - Comparação entre refletividade do radar e precipitação estimada para a Estação 14.	58

LISTA DE TABELAS

Tabela 2.1 - Classificação operacional da intensidade da chuva.....	7
Tabela 3.1 - Ranking das variáveis de radar mais relevantes para nowcasting de chuva forte.....	21
Tabela 3.2 - Comparação entre os trabalhos relacionados.....	23
Tabela 4.1 - Resumo das métricas de desempenho utilizadas para avaliar o modelo.	34
Tabela 5.1 - Abordagens consideradas na comparação experimental.	44
Tabela 5.2 - Desempenho global do modelo Random Forest para as cinco estações analisadas.....	45
Tabela 5.3 - Desempenho do modelo Random Forest para a Estação 12, estrati- ficado por faixa de intensidade de precipitação.	45
Tabela 5.4 - Desempenho do modelo STConvS2S por horizonte de previsão.	49
Tabela 5.5 - Desempenho do modelo STConvS2S por faixa de intensidade de pre- cipitação.	49
Tabela 5.6 - Comparação global entre persistência e STConvS2S no conjunto de teste.....	51
Tabela 5.7 - Comparação entre persistência e STConvS2S por horizonte de previsão.	51
Tabela 5.8 - Comparação entre persistência e STConvS2S por faixa de intensi- dade de precipitação.	52
Tabela 5.9 - Comparação pontual entre precipitação medida, precipitação esti- mada e valores RGB do radar para as estações analisadas em 03/03/2019 às 19:00 UTC.	54
Tabela A.1 - Informações das estações do sistema WebSirene utilizadas no estudo..	65

LISTA DE ACRÔNIMOS

R^2 Coeficiente de Determinação

CEFET/RJ Centro Federal de Educação Tecnológica Celso Suckow da Fonseca

DEM Modelo Digital de Elevação

LNCC Laboratório Nacional de Computação Científica

MAE Erro Absoluto Médio

PPI Plan Position Indicator

RMSE Raiz do Erro Quadrático Médio

STConvS2S Spatiotemporal Convolutional Sequence-to-Sequence

SUMÁRIO

1	INTRODUÇÃO	1
1.1	CONTEXTUALIZAÇÃO	1
1.2	MOTIVAÇÃO	2
1.3	OBJETIVOS.....	3
1.4	ORGANIZAÇÃO DOS CAPÍTULOS.....	4
1.5	INFORMAÇÕES SOBRE USO DE IA NESTE TRABALHO.....	4
2	FUNDAMENTAÇÃO TEÓRICA	5
2.1	CONCEITOS METEOROLÓGICOS FUNDAMENTAIS	5
2.1.1	PRECIPITAÇÃO E SEUS PROCESSOS FÍSICOS	5
2.1.2	INTENSIDADES DE CHUVA E CLASSIFICAÇÕES OPERACIONAIS	6
2.2	RADARES METEOROLÓGICOS	8
2.2.1	PRINCÍPIOS DE FUNCIONAMENTO DO RADAR METEOROLÓGICO ..	8
2.2.2	VARREDURA PPI (PLAN POSITION INDICATOR)	9
2.2.3	REFLETIVIDADE E RELAÇÃO Z-R.....	10
2.2.4	LIMITAÇÕES OPERACIONAIS	11
2.3	ESTAÇÕES DE SUPERFÍCIE, CARACTERÍSTICAS E LIMITAÇÕES	12
2.4	INTEGRAÇÃO ENTRE RADAR E ESTAÇÕES DE SUPERFÍCIE	12
2.4.1	CALIBRAÇÃO RADAR-PLUVIÔMETRO E ASSOCIAÇÃO DOS DADOS.	13
2.4.2	DESBALANCEAMENTO EM DADOS DE PRECIPITAÇÃO	13
2.4.3	TÉCNICAS DE BALANCEAMENTO	14
2.5	NOWCASTING DE PRECIPITAÇÃO	14
2.5.1	DEFINIÇÃO E ESCALAS DE PREVISÃO EM CURTO PRAZO	14
2.5.2	ABORDAGENS DE NOWCASTING E PRINCIPAIS DESAFIOS	15
2.6	APRENDIZADO SUPERVISIONADO PARA ESTIMATIVA DE PRECIPITAÇÃO	16
2.7	MODELO DIGITAL DE ELEVAÇÃO (DEM).....	17
3	TRABALHOS RELACIONADOS.....	19
3.1	METODOLOGIA DE BUSCA BIBLIOGRÁFICA	19
3.2	APRESENTAÇÃO DOS TRABALHOS.....	19
3.3	COMPARAÇÃO DOS TRABALHOS	22
4	METODOLOGIA	24
4.1	FORMULAÇÃO DO PROBLEMA	24
4.2	FLUXO GERAL DO PROCESSO	25
4.3	COLETA E ORGANIZAÇÃO DOS DADOS.....	25

4.4	PRÉ-PROCESSAMENTO E CONTROLE DE QUALIDADE	28
4.5	CONSTRUÇÃO DAS SEQUÊNCIAS ESPAÇO-TEMPORAIS.....	29
4.6	CONSTRUÇÃO DE ALVOS ESPARSOS COM MÁSCARA DE OBSERVAÇÃO	30
4.7	TREINAMENTO DO MODELO	32
4.8	AVALIAÇÃO DO MODELO	33
4.9	ABORDAGENS DE REFERÊNCIA.....	35
4.10	DISCUSSÃO	35
5	EXPERIMENTOS E RESULTADOS	37
5.1	ANÁLISE EXPLORATÓRIA DOS DADOS	37
5.1.1	DISTRIBUIÇÃO DA PRECIPITAÇÃO OBSERVADA.....	37
5.1.2	DIAGNÓSTICO DE DESBALANCEAMENTO.....	38
5.1.3	DISTRIBUIÇÃO DA REFLETIVIDADE DO RADAR.....	38
5.1.4	DISTRIBUIÇÃO DO RELEVO.....	38
5.1.5	RELAÇÃO ENTRE RADAR, RELEVO E PRECIPITAÇÃO.....	40
5.1.6	CONSIDERAÇÕES PARA A MODELAGEM.....	40
5.2	MODELOS DE REFERÊNCIA E ESTRATÉGIA DE COMPARAÇÃO	41
5.2.1	BASELINE DE PERSISTÊNCIA.....	41
5.2.2	EXPERIMENTO PRELIMINAR COM RANDOM FOREST LOCAL	42
5.2.3	COMPARAÇÃO COM O MODELO ESPAÇO-TEMPORAL	42
5.2.4	MÉTRICAS DE AVALIAÇÃO DOS BASELINES	43
5.2.5	SÍNTESE DA ESTRATÉGIA DE COMPARAÇÃO	43
5.3	EXPERIMENTO PRELIMINAR DE CALIBRAÇÃO LOCAL	44
5.3.1	RESULTADOS DO RANDOM FOREST LOCAL	44
5.3.2	ANÁLISE POR INTENSIDADE DE PRECIPITAÇÃO	45
5.3.3	IMPACTO DA ELEVAÇÃO NO RANDOM FOREST LOCAL.....	46
5.4	MODELO ESPAÇO-TEMPORAL COM STCONVS2S	46
5.4.1	PREPARAÇÃO DAS SEQUÊNCIAS DE ENTRADA	47
5.4.2	CONSTRUÇÃO DOS ALVOS MASCARADOS	47
5.4.3	CONFIGURAÇÃO DE TREINAMENTO	48
5.5	RESULTADOS DO MODELO STCONVS2S	48
5.5.1	DESEMPENHO GLOBAL POR HORIZONTE DE PREVISÃO	48
5.5.2	DESEMPENHO POR INTENSIDADE DE PRECIPITAÇÃO	49
5.5.3	ANÁLISE DO VIÉS	50
5.6	COMPARAÇÃO ENTRE STCONVS2S E PERSISTÊNCIA	50
5.7	VISUALIZAÇÃO ESPACIAL DAS ESTIMATIVAS.....	52
5.8	DISCUSSÃO DOS RESULTADOS.....	55
6	CONCLUSÃO	59
6.1	ANÁLISE RETROSPECTIVA	59

6.2 TRABALHOS FUTUROS	59
REFERÊNCIAS	61
APÊNDICE A - Detalhamento das Estações do Sistema WebSirene	64

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO

A previsão de chuva é um dos principais desafios da meteorologia, principalmente em cidades grandes e sujeitas a enchentes e deslizamentos, como o Rio de Janeiro. Nesse contexto, destaca-se o RioNowcast, um projeto de pesquisa e desenvolvimento voltado ao aprimoramento da previsão de chuva extrema na cidade do Rio de Janeiro. A plataforma é resultado de uma colaboração entre diversas instituições, incluindo o Centro Federal de Educação Tecnológica Celso Suckow da Fonseca (CEFET/RJ), o Laboratório Nacional de Computação Científica (LNCC), a Universidade Federal Fluminense e órgãos da Prefeitura do Rio de Janeiro, como o AlertaRio e o Centro de Operações. Essa parceria multidisciplinar combina dados meteorológicos, ferramentas de inteligência artificial e conhecimento técnico-operacional para desenvolver métodos de previsão de curto prazo aplicados ao contexto urbano. A participação do CEFET/RJ nesse projeto reforça a importância científica e prática de iniciativas que integram dados de radar, medições em superfície e modelos computacionais.

Os radares meteorológicos desempenham um papel essencial nesse tipo de previsão, porque conseguem observar a chuva com alta resolução temporal e espacial, mostrando onde e com que intensidade ela ocorre quase em tempo real. O Radar Meteorológico do Sumaré, por exemplo, fornece imagens em intervalos de aproximadamente dois minutos e cobre grande parte da Região Metropolitana do Rio de Janeiro. Essas imagens permitem acompanhar a formação, intensificação, deslocamento e dissipação de sistemas precipitantes quase em tempo real.

Entretanto, a refletividade observada pelo radar não corresponde diretamente à precipitação medida em superfície. Por isso, a integração entre dados de radar e medições de superfície torna-se necessária. Neste trabalho, são utilizadas observações pluviométricas do sistema WebSirene, que registra a precipitação em pontos fixos da cidade, permitindo relacionar os campos observados pelo radar com medidas reais de chuva em superfície.

A precipitação é um fenômeno naturalmente espaço-temporal. Sua evolução depende não apenas da intensidade observada em um ponto, mas também da organização regional dos núcleos de chuva, do deslocamento das células precipitantes e de sua evolução ao longo do tempo. Dessa forma, algoritmos de aprendizado baseados apenas em relações locais entre refletividade e precipitação tendem a apresentar limitações na representação da dinâmica espacial dos sistemas precipitantes.

Diante disso, este trabalho tem como foco a implementação e avaliação de um modelo espaço-temporal para previsão imediata de precipitação a partir de sequências de imagens do Radar Meteorológico do Sumaré e observações das estações WebSirene. A arquitetura adotada é a *Spatiotemporal Convolutional Sequence-to-Sequence* (STConvS2S)

(Castro et al. 2021), projetada para capturar padrões temporais e espaciais em sequências de dados meteorológicos. Seu desempenho é comparado com abordagens de referência, incluindo um modelo de persistência e um modelo local baseado em Random Forest, permitindo avaliar os ganhos obtidos pela modelagem espaço-temporal em relação a baselines mais simples.

1.2 MOTIVAÇÃO

Eventos de chuva intensa na Região Metropolitana do Rio de Janeiro frequentemente provocam alagamentos, deslizamentos e diversos impactos socioeconômicos que afetam diretamente a segurança e o cotidiano da população. Embora existam sistemas de monitoramento pluviométrico e meteorológico, ainda há dificuldades em estimar com precisão a distribuição espacial da chuva em tempo quase real, sobretudo em áreas com baixa densidade de estações ou em regiões montanhosas, onde o efeito orográfico altera significativamente tanto a precipitação quanto a capacidade de observação do radar.

Os radares meteorológicos, como o Radar do Sumaré, oferecem observações contínuas com alta resolução temporal e espacial, sendo fundamentais para o monitoramento de eventos convectivos e de rápida evolução. No entanto, a refletividade observada pelo radar não representa diretamente a precipitação em superfície; por isso, a calibração com dados medidos por estações pluviométricas é essencial para produzir estimativas confiáveis. Porém, essa calibração enfrenta desafios importantes, como o forte desbalanceamento entre registros de chuva e de ausência de chuva, além das distorções causadas pelo relevo, que podem bloquear ou atenuar parcialmente o feixe do radar.

Além disso, a previsão imediata de precipitação exige a modelagem da evolução temporal dos campos de chuva. Métodos simples, como a persistência, assumem que o padrão atual de precipitação se mantém no futuro, funcionando como uma referência operacional básica. Algoritmos de aprendizado supervisionado, como o Random Forest, permitem avaliar a relação entre refletividade e precipitação em pontos específicos, mas não capturam explicitamente a dinâmica espacial dos sistemas precipitantes. Por outro lado, arquiteturas espaço-temporais, como a STConvS2S, operam sobre sequências de imagens e são capazes de explorar padrões de deslocamento, intensificação e dissipação da precipitação ao longo do tempo.

Nesse contexto, a motivação deste trabalho está em avaliar se uma arquitetura espaço-temporal baseada em redes convolucionais é capaz de melhorar a previsão imediata de precipitação quando comparada a baselines mais simples. A comparação entre STConvS2S, persistência e Random Forest local permite investigar de forma mais clara os ganhos e limitações associados ao uso de algoritmos de aprendizado capazes de explorar simultaneamente a estrutura espacial e temporal dos dados de radar.

1.3 OBJETIVOS

O objetivo geral deste trabalho é implementar e avaliar um modelo espaço-temporal baseado na arquitetura STConvS2S para previsão imediata de precipitação na Região Metropolitana do Rio de Janeiro, utilizando dados do Radar Meteorológico do Sumaré e medições pluviométricas das estações WebSirene. O desempenho do modelo é comparado com baselines de referência, incluindo persistência e Random Forest local, a fim de analisar os ganhos obtidos pela modelagem espaço-temporal.

Para isso, são utilizadas sequências de imagens de radar como entrada do modelo, associadas a observações pluviométricas em superfície. Como as estações WebSirene correspondem a medições pontuais distribuídas irregularmente no espaço, a avaliação considera a correspondência entre os campos estimados pelo modelo e os pontos observados pelas estações, permitindo verificar a capacidade do modelo em representar a evolução espacial da precipitação.

Os objetivos específicos deste trabalho são:

1. Organizar e sincronizar os dados do Radar Meteorológico do Sumaré e das estações WebSirene, garantindo consistência temporal e espacial entre as fontes de informação.
2. Construir uma representação espaço-temporal dos dados de radar e das observações de superfície, adequada ao treinamento e avaliação de algoritmos de aprendizado de previsão imediata de precipitação.
3. Implementar a arquitetura STConvS2S para previsão de sequências futuras de precipitação a partir de sequências anteriores de imagens de radar.
4. Construir e avaliar baselines de comparação, incluindo o método de persistência e um modelo local baseado em Random Forest.
5. Avaliar o desempenho dos modelos por meio de métricas estatísticas, como Coeficiente de Determinação (R^2), Erro Absoluto Médio (MAE) e viés.
6. Analisar o comportamento dos modelos em diferentes faixas de intensidade de chuva, considerando a dificuldade associada à previsão de eventos moderados, fortes e extremos.
7. Gerar mapas e visualizações espaciais das previsões produzidas, permitindo comparar qualitativamente a estrutura espacial estimada pelos algoritmos avaliados com os padrões observados pelo radar e pelas estações.

1.4 ORGANIZAÇÃO DOS CAPÍTULOS

No Capítulo 2, são apresentados os conceitos teóricos necessários para a compreensão do trabalho, incluindo os princípios de funcionamento dos radares meteorológicos, as características das estações de superfície e uma breve introdução sobre técnicas de aprendizado supervisionado aplicadas à previsão de precipitação. O Capítulo 3 discute os principais trabalhos relacionados, abordando estudos que utilizam dados de radares meteorológicos, e também estratégias para aprimorar a estimativa de chuva em curto prazo. O Capítulo 4 descreve a metodologia proposta, detalhando o processo de construção do conjunto de calibração, o processamento dos dados, o treinamento do modelo e os métodos utilizados para avaliação dos resultados. O Capítulo 5 apresenta os experimentos realizados e os resultados obtidos a partir da aplicação do modelo proposto, incluindo análises exploratórias, métricas de desempenho e discussões sobre o comportamento do modelo em diferentes cenários de precipitação. No Capítulo 6 são apresentadas as conclusões deste trabalho, sintetizando os principais resultados alcançados, as limitações identificadas e as possibilidades de aprimoramento para aplicações futuras de previsão imediata de precipitação na Região Metropolitana do Rio de Janeiro.

1.5 INFORMAÇÕES SOBRE USO DE IA NESTE TRABALHO

Durante a estruturação deste trabalho, foram utilizadas ferramentas de IA generativa exclusivamente para revisão de linguagem, reescrita pontual e sugestões de organização textual. Todo o conteúdo técnico, as decisões metodológicas, os resultados e as conclusões são de autoria do discente. O material sugerido por IA foi integralmente verificado e editado.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo apresentamos o referencial teórico que fundamenta o desenvolvimento deste trabalho. Na Seção 2.1, introduzimos os conceitos meteorológicos fundamentais. Na Seção 2.2, abordamos os princípios relacionados aos radares meteorológicos. Na Seção 2.3, descrevemos as características das estações de superfície. Na Seção 2.4, discutimos a integração entre radar e estações de superfície. Na Seção 2.5, apresentamos os conceitos importantes de previsão imediata de precipitação. Na Seção 2.6, tratamos do aprendizado supervisionado aplicado à estimativa de chuva.

2.1 CONCEITOS METEOROLÓGICOS FUNDAMENTAIS

Nesta seção apresentamos os principais conceitos meteorológicos fundamentais utilizados neste trabalho. A Seção 2.1.1 descreve os processos físicos envolvidos na formação da precipitação e a Seção 2.1.2 apresenta as classificações operacionais de intensidade de chuva.

2.1.1 Precipitação e Seus Processos Físicos

A precipitação corresponde ao retorno da água da atmosfera à superfície na forma líquida ou sólida. Sua formação envolve processos microfísicos de condensação e crescimento de partículas em nuvens, que dependem essencialmente da presença de umidade e de mecanismos de ascensão do ar capazes de produzir resfriamento e saturação (Ayoade 1996).

Além dos processos gerais de formação da precipitação, diferentes mecanismos atmosféricos podem levar ao desenvolvimento de tipos distintos de chuva. Esses mecanismos estão relacionados principalmente à forma como o ar úmido é forçado a subir na atmosfera, e cada um deles produz características próprias de intensidade, duração e distribuição espacial.

Segundo Ayoade (1996), a precipitação do tipo convectivo está associada ao desenvolvimento de nuvens formadas a partir do movimento vertical de uma massa de ar que se torna mais quente e menos densa do que o meio ambiente. Esse aquecimento da superfície favorece a ascensão rápida do ar, que se resfria, condensa e origina nuvens de grande desenvolvimento vertical. Esse tipo de precipitação é comum em dias quentes e úmidos, apresenta forte intensidade e curta duração, e frequentemente está associada à ocorrência de trovoadas. A Figura 2.1 ilustra o processo de formação da chuva convectiva.

A chuva frontal, ou chuva ciclônica, ocorre quando massas de ar com diferentes temperaturas interagem em grande escala, típicas dos sistemas de baixa pressão. Segundo Ayoade (1996), esse tipo de precipitação surge quando o ar mais quente é forçado a ascender sobre o ar mais frio e denso ao longo de uma frente, produzindo nuvens extensas




Figura 2.1: Ilustração do processo de formação de chuvas convectivas. A chuva convectiva é formada pela circulação atmosférica local, originada com a ascensão do ar quente. Fonte: Mundo Educação (<https://mundoeducacao.uol.com.br/geografia/tipos-chuva.htm>).

e chuva contínua e moderada. Por estar associada ao deslocamento de depressões atmosféricas, a chuva frontal tende a cobrir áreas amplas e apresentar maior duração do que a precipitação convectiva. Esse tipo de chuva está representado na Figura 2.2.

A precipitação orográfica ocorre quando uma corrente de ar úmido encontra uma barreira topográfica, como montanhas ou serras, sendo forçada a ascender. Durante essa ascensão, o ar se resfria, atinge a saturação e condensa, produzindo maior precipitação nas vertentes a barlavento. Já as vertentes a sotavento tendem a apresentar ar mais seco e aquecido, formando a chamada “sombra de chuva”, caracterizada pela redução significativa dos totais pluviométricos. A intensidade desse efeito depende da estabilidade atmosférica, da umidade e do alinhamento do relevo em relação aos ventos úmidos (Ayoade 1996). Esse processo é ilustrado na Figura 2.3.

2.1.2 Intensidades de Chuva e Classificações Operacionais

A intensidade da precipitação descreve a taxa com que a água atinge a superfície em determinado intervalo de tempo. Essa taxa, geralmente expressa em milímetros por hora (mm/h), é amplamente utilizada em monitoramento, pesquisa e operações meteorológicas, orientando decisões relacionadas à emissão de alertas, resposta a desastres e avaliação de riscos hidrometeorológicos (Santos, Cunha e Ribeiro-Neto 2019).

De forma operacional, a intensidade da chuva é dividida em faixas que facilitam a interpretação e a comunicação de eventos meteorológicos. Segundo a Defesa Civil do Município do Rio de Janeiro, considera-se chuva fraca quando a taxa de precipitação é inferior a 5 mm/h; moderada entre 5 e 25 mm/h; forte entre 25 e 50 mm/h; e muito forte ou extrema quando ultrapassa 50 mm/h. Esses intervalos funcionam como gatilhos oficiais para a ativação dos diferentes níveis operacionais do sistema municipal de alerta.




Figura 2.2: As frentes quentes e frias dão origem às chuvas frontais. Fonte: Mundo Educação (<https://mundoeducacao.uol.com.br/geografia/tipos-chuva.htm>).

Além de classificarem a intensidade, essas faixas também orientam o acionamento de estágios operacionais relacionados aos possíveis impactos. O nível de Observação indica a possibilidade de ocorrência de eventos de menor impacto. O nível de Atenção é acionado quando há maior probabilidade de chuva forte e risco de alagamentos ou pequenos deslizamentos. Já o Aviso Especial corresponde a situações de risco elevado ou iminência de desastres mais severos, como inundações ou deslizamentos de grande porte.

Para facilitar a visualização dessas categorias, bem como da intensidade correspondente de precipitação associada a cada faixa, a Tabela 2.1 apresenta um resumo dos intervalos de chuva e dos níveis operacionais adotados pela Defesa Civil.

Tabela 2.1: Classificação operacional da intensidade da chuva e níveis de alerta utilizados pela Defesa Civil do Município do Rio de Janeiro 2020.

Categoria	Intensidade (mm/h)	Classificação Operacional
Chuva fraca	< 5	Sem alerta ou Observação
Chuva moderada	5 – 25	Observação
Chuva forte	25 – 50	Atenção
Chuva muito forte / extrema	> 50	Aviso Especial

Logo, é necessário o monitoramento em alta resolução na análise e previsão de eventos de precipitação, especialmente em regiões urbanas e com grande variabilidade




Figura 2.3: As chuvas orográficas acontecem devido ao encontro entre uma massa de ar úmida e uma barreira orográfica, como uma montanha ou uma serra. Fonte: Mundo Educação (<https://mundoeducacao.uol.com.br/geografia/tipos-chuva.htm>).

espacial, como a Região Metropolitana do Rio de Janeiro. A chuva pode apresentar mudanças significativas em distâncias muito curtas e em intervalos de tempo reduzidos, o que faz com que instrumentos de baixa resolução temporal ou espacial nem sempre consigam registrar de forma adequada a evolução das precipitações. Em situações de risco, como eventos de chuva extrema que podem causar alagamentos ou deslizamentos, a capacidade de monitorar a precipitação minuto a minuto permite que alertas sejam emitidos com maior antecedência (Coelho e Nunes 2020).

2.2 RADARES METEOROLÓGICOS

Nesta seção apresentamos os princípios relacionados aos radares meteorológicos. Na Seção 2.2.1, são descritos os princípios básicos de funcionamento do radar meteorológico. A Seção 2.2.2 explica a Varredura PPI (Plan Position Indicator). A Seção 2.2.3 apresenta o conceito de refletividade e a relação entre refletividade e taxa de precipitação (relação Z-R). Por fim, a Seção 2.2.4 aborda as limitações operacionais associadas ao uso do radar, incluindo atenuação, bloqueio e ruídos.

2.2.1 Princípios de Funcionamento do Radar Meteorológico

O radar meteorológico é utilizado como principal entrada dos modelos, devido à sua capacidade de capturar rapidamente a evolução das áreas de chuva (Green 2024). Seu funcionamento é baseado na emissão de pulsos de energia eletromagnética em direção à atmosfera. Quando essa energia encontra partículas de água ou gelo, como gotas de chuva, flocos de neve ou granizo, uma parte do sinal retorna para a antena do radar. A intensidade desse sinal retornado, chamada de refletividade, indica a presença e a quantidade dessas

partículas no local observado (Kim, Kwon e Kim 2021).

Durante a operação, o radar realiza varreduras em diferentes direções e ângulos, permitindo observar a atmosfera em torno da antena de forma tridimensional. Cada pulso enviado retorna ao radar depois de um intervalo de tempo que depende da distância do alvo, o que possibilita construir imagens que representam onde estão as partículas de chuva ou gelo. A sequência dessas varreduras ao longo do tempo cria imagens contínuas, que permitem acompanhar a formação, o deslocamento e o fortalecimento das áreas de precipitação.

A intensidade do sinal que retorna ao radar permite estimar tanto a estrutura das nuvens quanto a intensidade da chuva, já que partículas maiores ou em maior quantidade geram retornos mais fortes. Dessa forma, o radar não mede a chuva diretamente, mas fornece uma estimativa indireta com alta resolução no tempo e no espaço (Green 2024).

As imagens produzidas pelos radares meteorológicos podem ser exibidas de diferentes maneiras, e cada forma de representação ajuda a destacar algum aspecto importante da precipitação ou da atmosfera (Byun e Cha 2025). Um dos formatos mais utilizados para a visualização dos dados de radar meteorológico é a composição em RGB (Red, Green, Blue), na qual os valores de refletividade são convertidos em cores para facilitar a interpretação qualitativa da precipitação. Segundo a Prefeitura do Rio de Janeiro, cores mais frias, como verde ou azul, estão associadas a núcleos de chuva fraca a moderada, enquanto cores quentes, como amarelo, laranja, vermelho e magenta, indicam precipitação moderada a forte ou muito forte. Essa representação cromática permite identificar rapidamente áreas de maior intensidade de refletividade.

2.2.2 Varredura PPI (Plan Position Indicator)

Os radares meteorológicos podem operar em diferentes modos de varredura, e um dos mais utilizados em aplicações operacionais é o *Plan Position Indicator* (PPI). Nesse tipo de varredura, o radar realiza uma rotação completa de 360° em torno do eixo vertical enquanto mantém um ângulo de elevação fixo, como é ilustrado na Figura 2.4. Ao longo dessa rotação, o radar emite pulsos eletromagnéticos e registra a intensidade do sinal refletido pelas partículas presentes na atmosfera, construindo uma imagem bidimensional da refletividade para aquele ângulo de elevação.

Ao contrário do que possa parecer à primeira vista, um produto PPI não corresponde a uma “fatia horizontal” da atmosfera. Isso ocorre porque, devido à inclinação fixa do feixe e à curvatura da Terra, a altura do volume amostrado aumenta conforme a distância ao radar. Assim, regiões próximas ao radar são observadas a altitudes mais baixas, enquanto pontos mais distantes são amostrados progressivamente acima da superfície. Essa geometria implica que um mesmo produto PPI representa diferentes alturas atmosféricas ao longo da área de cobertura, o que pode influenciar a interpretação da refletividade em regiões distantes ou com forte variação topográfica (Lukach Thomas Dally et al. 2022).




Figura 2.4: Representação esquemática da geometria da varredura do tipo Plan Position Indicator (PPI) em radares meteorológicos. O radar realiza uma rotação completa de 360° em torno do eixo vertical enquanto mantém um ângulo de elevação fixo, de modo que a altura do feixe aumenta progressivamente com a distância ao radar, em função da inclinação do feixe e da curvatura da Terra. Adaptado de Lukach Thomas Dally et al. 2022.

No caso do Radar do Sumaré, que opera tipicamente com ângulos de elevação baixos (próximos de 1° a 3°), o produto PPI permite capturar eficientemente a estrutura horizontal dos sistemas precipitantes, sendo amplamente utilizado em operações de monitoramento meteorológico. Entretanto, em áreas montanhosas, a elevação do feixe pode causar bloqueios orográficos e zonas de sombra, nas quais o radar observa a atmosfera acima da camada de precipitação ou sofre perda parcial do sinal. Por essa razão, técnicas de calibração com dados de superfície são essenciais para converter a refletividade observada em estimativas mais confiáveis de precipitação em solo, especialmente em regiões com relevo complexo, como a Região Metropolitana do Rio de Janeiro (Collier 1986).

O entendimento da geometria PPI é fundamental para interpretar corretamente a refletividade e para desenvolver modelos de previsão que utilizem dados de radar, uma vez que o nível atmosférico amostrado varia espacialmente, afetando a correspondência entre refletividade e chuva observada em superfície.

2.2.3 Refletividade e Relação Z-R

A refletividade é a principal variável medida pelo radar meteorológico e representa a intensidade do sinal que retorna ao radar após interagir com partículas presentes na atmosfera, como gotas de chuva, gelo ou granizo. Quanto maiores e mais numerosas

são essas partículas, maior é o sinal refletido de volta para a antena. Por esse motivo, áreas com chuva fraca apresentam valores menores de refletividade, enquanto regiões com chuva forte ou tempestades convectivas exibem valores mais elevados. A refletividade é expressa normalmente em decibéis (dBZ), escala que facilita a interpretação operacional dos diferentes níveis de intensidade detectados pelo radar.

Embora a refletividade forneça uma indicação sobre a presença e a concentração de hidrometeoros, ela não representa diretamente a quantidade de chuva que atinge a superfície. Para isso, utiliza-se a chamada relação Z–R, que estabelece uma conversão entre a refletividade medida pelo radar (Z) e a taxa de precipitação em superfície (R), geralmente expressa em milímetros por hora (mm/h). Essa relação é obtida por meio de ajustes empíricos e varia conforme o tipo de precipitação, já que diferentes estruturas de nuvem e tamanhos de gotas produzem respostas distintas no radar. Assim, a relação Z–R permite transformar a informação indireta fornecida pelo radar em uma estimativa aproximada da chuva real observada no solo (Kim, Kwon e Kim 2021).

2.2.4 Limitações Operacionais

O radar meteorológico disponibiliza monitoramento de precipitação com alta resolução temporal e espacial, porém apresenta limitações que podem afetar a qualidade das estimativas de chuva (Berne e Krajewski 2013). Uma delas é a atenuação, que ocorre quando o sinal emitido pelo radar perde intensidade ao atravessar regiões com chuva muito forte ou partículas de gelo. Nesses casos, a energia refletida de volta ao radar pode ser menor do que o esperado, levando à subestimativa da precipitação em áreas mais distantes.

Outra limitação importante é a blocagem, que acontece quando o relevo interfere no caminho do feixe do radar. Montanhas, morros e outras elevações podem bloquear total ou parcialmente o sinal, dificultando a detecção da chuva em certas direções. Em regiões com topografia complexa, como o Rio de Janeiro, esse efeito é particularmente relevante e pode gerar áreas de sombra onde o radar observa a atmosfera com menor precisão.

Além disso, os dados de radar estão sujeitos à presença de ruídos, que incluem retornos não associados à precipitação, como reflexões em edifícios, interferências eletromagnéticas, aves ou até mesmo ondas do mar. Esses ruídos precisam ser filtrados durante o processamento para evitar interpretações incorretas.

Essas limitações operacionais fazem com que, em algumas situações, o radar não consiga representar toda a estrutura da precipitação de forma precisa. Por isso, diversos trabalhos têm explorado a integração de dados de radar com outras fontes de observação, como produtos de satélite, visando melhorar o monitoramento e a previsão de curto prazo de precipitação (Tosiri et al. 2021).

2.3 ESTAÇÕES DE SUPERFÍCIE, CARACTERÍSTICAS E LIMITAÇÕES

As estações meteorológicas de superfície são instaladas em locais fixos visando medir continuamente as condições atmosféricas próximas ao solo. Podem ser automáticas, quando realizam medições e enviam dados de forma automática, ou convencionais, quando dependem de observadores. Ambos tipos de estações fornecem variáveis essenciais para o monitoramento meteorológico, como temperatura, umidade, vento, pressão atmosférica e, principalmente, precipitação, registrada por pluviômetros (Knippelberg 2019).

Neste trabalho, utilizam-se dados pluviométricos provenientes do sistema WebSirenes, operado pela Prefeitura do Rio de Janeiro. Essa rede de monitoramento é composta por sirenes e estações automáticas distribuídas em diferentes setores da cidade, com maior densidade em áreas urbanas consolidadas e em regiões de encosta sujeitas a deslizamentos. Essa configuração espacialmente concentrada permite captar com maior precisão a variabilidade da precipitação em curtas distâncias, o que é essencial para a caracterização de eventos convectivos, que costumam apresentar rápida evolução no ambiente urbano (Caseri, Santos e Stephany 2022).

Além disso, as estações do sistema WebSirene possuem resolução temporal de 15 minutos, o que permite acompanhar a evolução da chuva com maior nível de detalhe e captar variações rápidas que podem ocorrer em eventos intensos. Essa resolução mais alta é importante em regiões onde a chuva varia rapidamente, pois permite identificar com mais clareza variações bruscas, como as que acontecem em eventos convectivos (Caseri, Santos e Stephany 2022). No aspecto espacial, a distribuição irregular das estações pode deixar algumas áreas com pouca cobertura, especialmente em locais montanhosos ou mais afastados dos centros urbanos.

Apesar de serem a forma mais direta de medir a precipitação, as estações estão sujeitas a erros e incertezas que podem influenciar a qualidade dos dados registrados. Os principais problemas são as obstruções no pluviômetro que podem impedir o escoamento correto da água e levar à subestimação dos valores. Também podem ocorrer falhas de calibração ou manutenção dos sensores, resultando em leituras imprecisas ao longo do tempo. Em alguns casos, há ainda perdas de dados por falhas na transmissão ou interrupções temporárias no funcionamento da estação. Outro fator importante é o efeito do vento, que pode desviar as gotas de chuva e fazer com que parte delas não entre no pluviômetro, especialmente durante eventos mais intensos ou em áreas abertas e elevadas. Esses fatores mostram que, apesar de essenciais, as medições feitas pelas estações podem apresentar limitações e devem ser interpretadas cuidadosamente (Nanding, Ramirez e Han 2021).

2.4 INTEGRAÇÃO ENTRE RADAR E ESTAÇÕES DE SUPERFÍCIE

Nesta seção descrevemos a integração entre o radar e as estações de superfície. A seção 2.4.1 apresenta a calibração radar-pluviômetro e a associação de dados. Na se-

ção 2.4.2, é explicado o desbalanceamento em dados de precipitação. Por fim, a seção 2.4.3 apresenta técnicas de balanceamento.

2.4.1 Calibração Radar-Pluviômetro e Associação dos dados

A refletividade medida pelo radar fornece apenas uma estimativa indireta da chuva, pois representa o retorno do sinal após interagir com partículas presentes na atmosfera. Embora valores mais altos indiquem maior quantidade ou tamanho das gotas, essa medida não corresponde diretamente ao volume de precipitação daquele evento. Por isso, é necessária uma calibração com medições feitas pelos pluviômetros, comparando o valor da refletividade no ponto correspondente à estação com o registro real de chuva (Collier 1986).

Para calibrar os dados do radar com os valores medidos pelos pluviômetros, é necessário criar uma correspondência espacial entre eles. Cada estação está localizada em um ponto com coordenadas conhecidas, enquanto o radar gera uma imagem composta por pixels que representam diferentes áreas da região. Assim, o primeiro passo é identificar qual pixel do radar corresponde à posição exata da estação, o que exige converter suas coordenadas geográficas para o sistema utilizado pelo radar.

Uma vez feita essa conversão, a estação é localizada dentro do campo de varredura e seleciona-se o valor de refletividade do pixel correspondente, garantindo que a comparação com o dado de chuva esteja alinhada no espaço e no tempo. Esse procedimento é essencial para que os dados utilizados na calibração representem corretamente o mesmo local observado.

2.4.2 Desbalanceamento em Dados de Precipitação

Os dados de precipitação utilizados para treinar modelos de previsão de chuva possuem desbalanceamento entre as classes. Uma vez que na maior parte das observações não ocorreu chuva, ou chuva muito leve, enquanto eventos de chuva forte ou extrema são muito mais raros. Isso prejudica o desempenho do modelo, que tende a aprender melhor os padrões associados aos casos mais frequentes, principalmente a ausência de chuva, e subestima eventos de maior intensidade.

Esse comportamento gera um modelo enviesado, que apresenta bom desempenho quando a precipitação é fraca ou inexistente, mas tem dificuldade em representar casos de chuvas intensas, associadas a alagamentos e deslizamentos. Além disso, o desbalanceamento favorece o sobreajuste da classe majoritária. Nesse caso, o modelo passa a aprender apenas o comportamento predominante (chuva fraca ou zero), perde capacidade de generalizar corretamente para eventos menos frequentes. Essa dificuldade é amplamente discutida na literatura de aprendizado de máquina, que destaca o desbalanceamento como uma das principais causas de viés e perda de desempenho em modelos supervisionados (Krawczyk 2016).

2.4.3 Técnicas de Balanceamento

Para reduzir os efeitos do desbalanceamento dos dados de precipitação e melhorar a capacidade dos modelos em representar diferentes intensidades de chuva, é importante aplicar técnicas de balanceamento dos dados antes do treinamento. Essas técnicas ajustam a proporção entre as classes, permitindo que o modelo aprenda de forma mais equilibrada tanto os casos mais frequentes quanto os mais raros.

Uma forma de lidar com o desbalanceamento é a subamostragem, que reduz a quantidade de registros da classe majoritária, ou seja, a classe mais comum. Ao diminuir esses exemplos repetidos, o conjunto de dados fica mais equilibrado, porém, pode resultar na perda de informações úteis se muitos registros forem removidos. Outra abordagem é a sobreamostragem, que aumenta a quantidade de registros das classes minoritárias. Isso pode ser feito repetindo alguns exemplos já existentes ou utilizando métodos que criam novos registros a partir dos dados originais. A principal vantagem é ampliar a presença dos eventos raros, como chuvas fortes, sem descartar informações importantes da classe majoritária (Barella 2015).

Entre os métodos de sobreamostragem, destaca-se o SMOTE (Synthetic Minority Oversampling Technique). O SMOTE é um dos métodos de sobreamostragem mais utilizados na literatura, pois gera novos exemplos da classe minoritária por meio de interpolações entre amostras reais (Elreedy, Atiya e Kamalov 2023). Dessa forma, o conjunto de dados pode se tornar mais equilibrado e diverso, favorecendo o aprendizado em cenários com eventos raros. No entanto, a aplicação desse tipo de técnica requer cautela em problemas envolvendo dados físicos, como variáveis meteorológicas, uma vez que a geração de amostras sintéticas pode não preservar relações físicas complexas entre as variáveis observadas.

2.5 NOWCASTING DE PRECIPITAÇÃO

Nesta seção descrevemos Nowcasting de precipitação. A seção 2.5.1 apresenta a definição e escalas de previsão de curto prazo. Já na seção 2.5.2, são explicadas as abordagens de Nowcasting e principais desafios.

2.5.1 Definição e Escalas de Previsão em Curto Prazo

A previsão imediata de precipitação, conhecida como *nowcasting* (Wang et al. 2017), consiste em estimar como a chuva irá se comportar nas próximas horas, geralmente entre 1 e 6 horas de antecedência, utilizando dados de observação em tempo quase real. O Nowcasting é fundamental para antecipar eventos meteorológicos extremos, como tempestades intensas e inundações, permitindo a emissão de alerta com antecedência para reduzir riscos e proteger a população.

Esse tipo de previsão utiliza principalmente observações com alta resolução espa-

cial e temporal para acompanhar a evolução rápida da precipitação. Diferente das previsões numéricas, que dependem de modelos atmosféricos completos e demandam maior tempo de processamento, o Nowcasting trabalha com dados obtidos em intervalos curtos, como imagens de radar e medições das estações de superfície. Dessa forma, é possível identificar rapidamente a formação, o movimento e a intensidade da precipitação. Por isso, o Nowcasting é essencial em áreas urbanas e regiões vulneráveis a eventos extremos, onde pequenas variações podem causar impactos significativos em pouco tempo.

As escalas de curto prazo podem ser divididas em três faixas principais. A escala de ultracurto prazo abrange previsões de 0 a 30 minutos, sendo a mais sensível a mudanças rápidas e ideal para monitoramento operacional imediato. A escala de curto prazo cobre aproximadamente 30 minutos a 2 horas, período no qual ainda é possível acompanhar o deslocamento de sistemas precipitantes com base em observações diretas. Além da escala de curto prazo estendido, que pode chegar até 6 horas, combinando informações observadas com modelos de aprendizado de máquina para estimar a evolução da precipitação.

2.5.2 Abordagens de Nowcasting e Principais Desafios

As abordagens de Nowcasting dependem principalmente da análise de observações recentes para estimar como a chuva irá se comportar nos próximos minutos ou horas. Entre os métodos mais usados estão as técnicas de extrapolação da refletividade, que projetam o deslocamento das áreas de chuva a partir de sequências de imagens de radar. Esses métodos assumem que as nuvens e as áreas de precipitação mantêm forma e intensidade por um curto período, permitindo prever seu movimento de maneira simples e rápida.

O Nowcasting por extrapolação é amplamente utilizado devido à sua simplicidade, mas possui limitações, especialmente quanto à evolução rápida da precipitação. Bechini e Chandrasekar 2017 mostram que a estrutura das células de chuva pode mudar significativamente mesmo em intervalos curtos, o que impacta a qualidade da previsão. Além disso, a precipitação pode variar muito rapidamente no tempo e no espaço, sobretudo em eventos convectivos, que se formam e mudam de intensidade em poucos minutos. Isso dificulta prever não apenas o deslocamento da chuva, mas também seu crescimento ou enfraquecimento. Outro problema é a presença de ruídos nos dados de radar, como interferências do relevo, ecos falsos ou efeitos de atenuação, que podem distorcer a imagem e comprometer a qualidade da previsão.

Ademais, métodos baseados apenas na extrapolação costumam perder desempenho conforme o tempo de previsão aumenta. Isso acontece porque esses métodos não representam processos físicos importantes, como o surgimento de novas células de chuva ou a dissipação das anteriores. Essa limitação também está ligada ao tamanho dos sistemas de chuva. Quanto menores e mais instáveis, menor é o tempo em que podem ser previstos com precisão. Germann e Zawadzki 2002 mostram que pequenas células de chuva

mudam de forma muito rápido, o que diminui a capacidade dos métodos de extrapolação de acompanhar sua evolução.

2.6 APRENDIZADO SUPERVISIONADO PARA ESTIMATIVA DE PRECIPITAÇÃO

O uso de aprendizado supervisionado para estimar precipitação tem sido uma abordagem eficaz em estudos que utilizam dados de radar e estações de superfície. O problema é tratado como uma tarefa de regressão, em que o modelo aprende a prever um valor contínuo relacionado à intensidade da chuva (Liu et al. 2025). Essa abordagem é mais adequada do que classificações, pois permite representar diferentes níveis de precipitação, como chuva fraca, moderada, forte ou extrema, de forma quantitativa.

Para que o modelo consiga aprender a relação entre os dados observados e a intensidade da precipitação, é necessário converter os dados brutos em variáveis numéricas (Byun e Cha 2025). No caso dos radares meteorológicos, essas variáveis são extraídas dos diferentes produtos gerados pelo radar, como os campos de refletividade, as composições em RGB ou projeções horizontais em diferentes níveis da atmosfera. Cada uma dessas representações destaca aspectos específicos da chuva e contribui para descrever o estado das nuvens no momento da observação. Além disso, muitos estudos utilizam variáveis adicionais calculadas ao redor do ponto de interesse, como médias, máximos ou outros valores estatísticos na vizinhança, bem como informações de instantes anteriores (Castro et al. 2021). Essas variáveis ajudam a representar tendências de aumento, deslocamento ou dissipação da chuva, enriquecendo o conjunto de entrada utilizado pelo modelo.

Entre os algoritmos usados em tarefas de regressão, o Random Forest Regressor está entre os mais comuns devido à sua capacidade de lidar com relações complexas entre as variáveis e de manter um bom desempenho mesmo quando há ruídos nos dados (Ouallouche, Lazri e Ameur 2018). Esse modelo é formado por várias árvores de decisão, como ilustrado na Figura 2.5, que, ao trabalharem juntas, produzem estimativas mais estáveis e reduzem o risco de sobreajuste, aumentando a capacidade de generalização. Outra vantagem importante é que o Random Forest permite estimar a importância das variáveis de entrada, o que auxilia na interpretação do modelo e na identificação de quais informações parecem mais relevantes para a estimativa de chuva.

A avaliação do desempenho de modelos de regressão aplicados à precipitação é geralmente feita por meio de métricas como o Coeficiente de Determinação (R^2), o Erro Absoluto Médio (MAE) e o viés. O R^2 indica o quanto o modelo é capaz de explicar a variação dos valores observados, já o MAE mede, em média, o tamanho dos erros cometidos, e o viés avalia se o modelo tende a superestimar ou subestimar a precipitação. Cada uma dessas métricas fornece uma perspectiva complementar sobre o desempenho do modelo, permitindo uma avaliação mais completa.




Figura 2.5: Esquema do modelo Random Forest para estimativa de precipitação, com múltiplas árvores de decisão combinando as previsões para uma estimativa final. Fonte: Medium (<https://medium.com/@vk.viswa/surface-level-understanding-of-random-forest-regression-3bac37e06f3e>).

Ademais, é relevante analisar o desempenho do modelo em diferentes faixas de intensidade de chuva. Essa etapa é importante porque o comportamento do modelo pode variar entre situações de chuva fraca, moderada, forte ou extrema. Em muitos casos, os modelos apresentam bom desempenho para precipitações leves, mas têm maior dificuldade em prever eventos mais intensos, devido ao evento aparecer com menos frequência na base de dados, sendo mais raro de ocorrer (Coelho e Nunes 2020). A análise por faixas permite identificar essas diferenças e contribui para uma interpretação mais detalhada dos resultados obtidos.

Essas etapas, que incluem a definição das variáveis de entrada, a escolha do modelo e a avaliação por diferentes métricas e faixas de intensidade, formam a base do aprendizado supervisionado aplicado à estimativa de precipitação. Esse conjunto de técnicas possibilita analisar de forma mais completa os dados observados, aprimorando a qualidade das estimativas e contribuindo para aplicações operacionais e estudos relacionados aos processos de chuva e previsão em curto prazo.

2.7 MODELO DIGITAL DE ELEVAÇÃO (DEM)

O Modelo Digital de Elevação (DEM) é uma representação numérica da superfície terrestre que descreve a altitude do terreno em relação ao nível médio do mar. Esse tipo de dado é geralmente estruturado em formato de grade, na qual cada célula representa um valor de elevação associado a uma posição geográfica específica. Os Modelos Digitais de Elevação são amplamente utilizados em estudos ambientais, geográficos e hidrológicos, pois permitem representar e analisar características do relevo de forma quantitativa (Sirtoli, Cruz e Mantovani 2008).

A informação topográfica fornecida por um DEM é especialmente relevante em estudos meteorológicos e hidrológicos, uma vez que o relevo pode influenciar diretamente a circulação atmosférica e os padrões de precipitação. Em regiões montanhosas, por exemplo, massas de ar úmido podem ser forçadas a subir ao encontrar barreiras topográficas, resfriando-se e favorecendo a formação de nuvens e precipitação, fenômeno conhecido como precipitação orográfica. A Figura 2.6 apresenta o Modelo Digital de Elevação da região do estado do Rio de Janeiro, evidenciando a variação altimétrica do terreno e a presença de áreas montanhosas que podem influenciar a distribuição espacial da precipitação.



Figura 2.6: Modelo Digital de Elevação (DEM) da região do estado do Rio de Janeiro, gerado a partir de dados da Shuttle Radar Topography Mission (SRTM) com resolução aproximada de 30 m. Os dados foram obtidos e processados utilizando a biblioteca *elevation*.

Além disso, o relevo pode afetar a observação realizada por radares meteorológicos. Em áreas com topografia complexa, montanhas e elevações podem bloquear parcialmente o feixe do radar ou causar atenuação do sinal, resultando em áreas de sombra ou distorções na estimativa da precipitação. Dessa forma, a inclusão de informações topográficas em análises meteorológicas pode contribuir para uma melhor interpretação dos dados de radar e para a construção de modelos mais representativos das condições atmosféricas locais.

Em aplicações de modelagem e aprendizado de máquina, o DEM pode ser utilizado como variável auxiliar, fornecendo informações estáticas do terreno que ajudam a contextualizar a distribuição espacial da precipitação (Sirtoli, Cruz e Mantovani 2008). A incorporação dessas variáveis pode auxiliar na identificação de padrões associados à influência do relevo nos processos meteorológicos, especialmente em regiões com forte variabilidade topográfica.

3 TRABALHOS RELACIONADOS

Neste capítulo apresentamos os principais trabalhos relacionados ao tema deste estudo, com foco em pesquisas que utilizam dados de radar meteorológico e técnicas de aprendizado supervisionado para estimar ou prever precipitação em curto prazo. Inicialmente, a Seção 3.1 descreve a metodologia de busca bibliográfica adotada para a seleção dos trabalhos analisados. Em seguida, a Seção 3.2 apresenta resumidamente a abordagem dos trabalhos, suas metodologias, resultados e a conclusão dos autores. Por fim, a Seção 3.3 apresenta uma comparação entre os trabalhos.

3.1 METODOLOGIA DE BUSCA BIBLIOGRÁFICA

A seleção dos trabalhos relacionados foi realizada por meio de uma busca sistemática em bases de dados científicas amplamente utilizadas na área de Engenharia, Ciências Exatas e da Terra. As buscas bibliográficas foram realizadas por meio do Portal de Periódicos da CAPES, que agrega diferentes bases de dados internacionais, incluindo IEEE Xplore, Scopus e editoras científicas relevantes, concentrando estudos nas áreas de radar meteorológico, aprendizado de máquina e previsão imediata de precipitação.

As buscas foram conduzidas utilizando combinações de palavras-chave relacionadas a radar meteorológico, estimativa de precipitação e técnicas de aprendizado de máquina. No Portal CAPES, com ênfase em trabalhos indexados na base IEEE Xplore, foi utilizada a seguinte string de busca:

```
(weather radar OR radar reflectivity) AND
(rainfall estimation OR precipitation nowcasting) AND
(machine learning)
```

Essa estratégia permitiu recuperar estudos que abordam a utilização de dados de radar meteorológico em conjunto com métodos supervisionados de aprendizado de máquina para estimar ou prever a precipitação em curto prazo. Os trabalhos retornados foram analisados com base em sua relevância temática, considerando estudos que utilizam dados de radar meteorológico para estimativa ou previsão de precipitação em curto prazo. A partir desse processo, foram selecionados os trabalhos que mais se relacionam com o escopo deste estudo.

3.2 APRESENTAÇÃO DOS TRABALHOS

Liu et al. 2025 propuseram um modelo de previsão imediata de precipitação baseado em *deep learning*, combinando observações de radar com dados de vapor d'água precipitável derivados de GNSS (GNSS-PWV). O estudo foi realizado na região de Hong

Kong, utilizando o conjunto de dados HKO-7, composto por imagens de refletividade com resolução espacial de 1 km e intervalo temporal de 6 minutos, além de uma rede com 15 estações GNSS que fornecem PWV na mesma resolução temporal.

O modelo utilizou uma arquitetura do tipo codificador-decodificador, construída a partir de camadas convolucionais e recorrentes, como ConvLSTM e TrajGRU. A proposta introduziu duas contribuições principais. A primeira foi um módulo de fusão de dados, no qual as séries temporais de vapor d'água precipitável (PWV), obtidas por GNSS, foram convertidas em imagens e combinadas com os campos de refletividade do radar. Essa fusão permitiu que o modelo utilizasse, ao mesmo tempo, informações sobre a estrutura das nuvens e sobre o conteúdo de umidade disponível na atmosfera. A segunda contribuição foi um mecanismo de atenção temporal, inspirado em técnicas de realce de canais, que identificou quais momentos da sequência de entrada foram mais relevantes para a previsão e ajustou o peso dessas informações durante o processamento.

Para avaliar o desempenho do modelo, os autores converteram a refletividade prevista em intensidade de chuva utilizando uma relação do tipo Z-R. Em seguida, calcularam métricas operacionais amplamente utilizadas em previsão imediata, como a Probabilidade de Detecção (POD), a Taxa de Falsos Alarmes (FAR), o Índice de Sucesso Crítico (CSI) e o Heidke Skill Score (HSS). Os testes foram realizados para três faixas de intensidade de precipitação: 0,5 mm/h, 5 mm/h e 30 mm/h.

Os autores mostraram que a configuração FSE-TrajGRU, que integra dados de radar e GNSS-PWV e utiliza um mecanismo de atenção temporal, apresentou o melhor desempenho entre as versões testadas. De modo geral, os resultados indicaram que combinar diferentes fontes de informação atmosférica e destacar os momentos mais relevantes da sequência ajudaram o modelo a representar melhor a evolução das tempestades e a melhorar a previsão de chuva intensa.

Wang et al. 2022 investigaram quais variáveis de radar são mais relevantes para prever chuva forte em curtíssimo prazo, utilizando diferentes métodos de aprendizado de máquina. O estudo utilizou dados de um radar meteorológico dual-polarimétrico e combinou informações de refletividade, conteúdo integrado de água, volume das células de chuva e outras variáveis derivadas para estimar a evolução da precipitação nos próximos 30 a 60 minutos.

Foram testados vários algoritmos supervisionados, como Random Forest, Lasso Regression e Support Vector Regression, com o objetivo de identificar quais variáveis derivadas do radar possuem maior capacidade de prever chuva forte em horizontes de 30 e 60 minutos. A Tabela 3.1 apresenta o ranking dessas variáveis para diferentes cenários de avaliação, permitindo identificar quais atributos contribuem de forma mais significativa para o desempenho dos modelos.

Tabela 3.1: Ranking das variáveis de radar mais relevantes para nowcasting de chuva forte, considerando horizontes de 30 e 60 minutos em dois métodos de avaliação (CC e MSL) [Wang et al. 2022].

Variable	CC				MSL			
	Mean Rain Rate		Top 10% Mean Rain Rate		Mean Rain Rate		Top 10% Mean Rain Rate	
	30 Min	60 Min	30 Min	60 Min	30 Min	60 Min	30 Min	60 Min
R_{mj}	1	6	1	7	4	5	1	1
R_{mn}	11	6	11	11	4	1	10	11
θ	17	17	13	16	16	13	14	6
$MeanZ$	1	1	1	1	1	5	5	1
$Area$	8	13	8	11	9	9	5	6
$Volume$	1	1	1	1	9	1	10	1
Top	11	6	8	7	13	9	5	14
$Base$	1	6	1	1	1	13	5	11
$MaxZ$	8	13	11	1	4	5	5	6
$MaxZ_{hgt}$	8	6	13	7	13	13	14	17
$AvgVIL$	1	6	8	11	9	9	10	6
$MaxVIL$	1	1	1	1	9	5	1	6
U	15	13	16	11	16	9	17	16
V	11	6	13	7	4	16	10	14
$Direction$	15	16	17	16	13	16	14	11
$MeanRR$	1	1	1	15	1	1	1	1
$Top10\%$	11	1	1	1	4	1	1	1

Os resultados mostraram que variáveis relacionadas à estrutura espacial da precipitação, como a refletividade média ($MeanZ$), o volume da área precipitada ($Volume$) e os valores máximos de refletividade ($MaxZ$), apareceram consistentemente entre as mais importantes nos diferentes horizontes de previsão. Isso indica que atributos que representam a intensidade e a organização das células de chuva são fundamentais para a previsão imediata.

Esses resultados confirmam a importância da refletividade como principal variável de entrada na estimativa de precipitação a partir de radar. Além disso, validam o uso de modelos supervisionados, como o Random Forest, para melhorar a estimativa de chuva com base em dados observacionais.

Huang et al. 2019 apresentaram um estudo cujo objetivo é classificar e prever, em curtíssimo prazo, episódios de granizo e outros fenômenos convectivos severos utilizando produtos de radar C-band e o algoritmo Random Forest. O trabalho utilizou observações de eventos registradas entre 2008 e 2019 na região de Tianshui, na China, combinando variáveis derivadas do radar, como refletividade, topos de eco, VIL e velocidade radial, com informações fornecidas por um sistema automático de identificação e rastreamento

de tempestades (SCIT).

O modelo foi treinado com dados do período de 2008 a 2017 e avaliado posteriormente em eventos independentes registrados entre 2018 e 2019. Os autores mostram que o classificador apresentou boa capacidade de distinguir quatro categorias de granizo, isolado, acompanhado de vento forte, associado à chuva intensa ou em combinações desses cenários, obtendo um erro de generalização de apenas 4,2%. Na etapa de previsão imediata, considerando horizontes entre 15 minutos e 1 hora, o modelo atingiu valores de desempenho consistentes, com médias de 74,8% para POD, 60,8% para CSI e 24,4% para FAR.

De maneira geral, os autores demonstraram que o Random Forest consegue identificar padrões relevantes nos produtos de radar e produzir previsões consistentes, superando métodos manuais frequentemente utilizados na operação meteorológica. O estudo reforçou que algoritmos supervisionados são adequados para lidar com fenômenos convectivos de rápida evolução. Além de confirmar que variáveis derivadas diretamente da refletividade são adequadas para estimar a intensidade e a evolução da precipitação a curto prazo.

3.3 COMPARAÇÃO DOS TRABALHOS

Observamos que os trabalhos analisados apresentaram diferentes estratégias para utilizar dados de radar meteorológico em tarefas de curto prazo, seja para previsão de precipitação ou para identificação de fenômenos convectivos. No caso de abordagens baseadas em aprendizado profundo, como o de Liu et al. 2025, os melhores resultados foram obtidos quando diferentes fontes de informação atmosférica foram combinadas, integrando dados de radar e de vapor d'água precipitável para melhorar a representação da evolução das tempestades. Em contrapartida, estudos que utilizam algoritmos supervisionados tradicionais, como Wang et al. 2022 e Huang et al. 2019, mostraram que variáveis derivadas da refletividade, como valores médios, máximos e medidas relacionadas ao volume precipitado, desempenham papel central no desempenho dos modelos.

A Tabela 3.2 sintetiza as principais características dos trabalhos analisados, destacando as técnicas utilizadas, os tipos de dados empregados e os objetivos de cada abordagem. Essa comparação permite posicionar este trabalho em relação à literatura, evidenciando o uso combinado de aprendizado profundo, dados de radar e foco em previsão imediata de precipitação.

A principal diferença entre os estudos analisados e este trabalho está na forma de integração entre radar e observações de superfície. Enquanto Liu et al. 2025 utilizam uma abordagem de aprendizado profundo com fusão de dados de radar e GNSS-PWV, este trabalho integra sequências de imagens do Radar Meteorológico do Sumaré com medições pluviométricas do sistema WebSirene. A arquitetura principal adotada é a STConvS2S, capaz de explorar simultaneamente a estrutura espacial e a evolução temporal dos sistemas

Trabalho	DL	RF	Rad	VarZ	Prev	Class
Liu et al. 2025	✓	—	✓	—	✓	—
Wang et al. 2022	—	✓	✓	✓	✓	—
Huang et al. 2019	—	✓	✓	✓	—	✓
Este trabalho	✓	✓	✓	—	✓	—

Tabela 3.2: Comparação entre os trabalhos relacionados quanto às técnicas de modelagem (DL, RF), tipos de dados utilizados (Rad, VarZ) e objetivos principais (Prev, Class).

precipitantes.

Além disso, este trabalho também utiliza algoritmos de aprendizado de referência, como Random Forest local, e o baseline de persistência, permitindo comparar a abordagem espaço-temporal proposta com estratégias mais simples. Dessa forma, a pesquisa se diferencia por avaliar uma arquitetura profunda sequência-para-sequência aplicada diretamente a dados locais do Radar do Sumaré e das estações WebSirene, com foco na previsão imediata de precipitação em ambiente urbano.

4 METODOLOGIA

Neste capítulo apresentamos a metodologia utilizada para a estimativa de precipitação a partir da integração entre os dados do Radar Meteorológico do Sumaré e as medições de estações de superfície utilizadas no sistema WebSirene. A Seção 4.1 apresenta a formulação do problema, seguida pela Seção 4.2, que descreve o fluxo geral da metodologia adotada. A Seção 4.3 detalha o processo de coleta e organização dos dados, enquanto a Seção 4.4 apresenta as etapas de pré-processamento e controle de qualidade. Em seguida, a Seção 4.5 descreve a construção das sequências espaço-temporais utilizadas pelo modelo, e a Seção 4.6 apresenta a geração dos alvos esparsos e das máscaras de observação. As estratégias de treinamento e avaliação do modelo são discutidas, respectivamente, nas Seções 4.7 e 4.8. Por fim, a Seção 4.9 apresenta os modelos de referência utilizados para comparação experimental, e a Seção 4.10 discute as principais características e limitações da metodologia proposta.

4.1 FORMULAÇÃO DO PROBLEMA

A estimativa de precipitação em curto prazo em ambientes urbanos representa um desafio significativo devido à forte variabilidade espacial e temporal da chuva, especialmente em regiões de relevo complexo como a Região Metropolitana do Rio de Janeiro. Embora os radares meteorológicos forneçam observações contínuas da atmosfera, a refletividade captada pelo radar não corresponde diretamente à precipitação em superfície, sendo influenciada por fatores como altura do feixe, tipo de hidrometeoro, atenuação e efeitos orográficos.

Por outro lado, as estações de superfície realizam medições diretas de chuva, porém apresentam cobertura espacial limitada e não capturam a estrutura tridimensional dos sistemas precipitantes. Assim, o problema central consiste em integrar duas fontes de dados com características distintas, radar e pluviômetros, para produzir estimativas mais representativas da precipitação observada na superfície.

Este trabalho formula o problema como uma tarefa de estimativa de precipitação a partir das informações de refletividade do Radar Meteorológico do Sumaré, ajustadas às observações registradas pelas estações do sistema WebSirene. O desafio adicional está no desbalanceamento dos dados, uma vez que eventos de chuva forte ocorrem com baixa frequência, enquanto observações de chuva fraca ou ausência de precipitação são muito mais comuns.

Dessa forma, o problema envolve (i) sincronizar temporal e espacialmente as duas fontes de dados, (ii) representar as medições pontuais das estações em uma estrutura compatível com a grade regular do radar, e (iii) desenvolver um modelo capaz de explorar padrões espaciais e temporais da refletividade para estimar a precipitação futura em

superfície. A formulação apresentada estabelece a base para as etapas subsequentes da metodologia.

4.2 FLUXO GERAL DO PROCESSO

A metodologia deste estudo foi organizada em etapas sequenciais, como ilustrado na Figura 4.1, com o objetivo de integrar os dados do Radar Meteorológico do Sumaré e das estações pluviométricas do sistema WebSirene em um conjunto de dados adequado ao treinamento de um modelo espaço-temporal de previsão de precipitação. O processo tem início com a coleta e organização dos dados, incluindo as imagens de radar e os registros de precipitação observada em superfície. Em seguida, os dados são sincronizados temporalmente e ajustados para uma mesma resolução espacial e temporal.

Na etapa de pré-processamento, as imagens do radar são agregadas em intervalos de 15 minutos e redimensionadas para uma grade regular de (256×256) pixels. A redução da resolução espacial foi adotada para viabilizar o treinamento do modelo espaço-temporal em termos de uso de memória e custo computacional, uma vez que as sequências de imagens completas (656×654) exigiriam maior capacidade de armazenamento e processamento. Paralelamente, as medições das estações WebSirene são associadas aos pixels correspondentes da grade do radar, permitindo a construção de campos esparsos de precipitação observada. Para cada instante, também é gerada uma máscara binária indicando os pixels nos quais há observação pluviométrica disponível.

A partir dessa estrutura, são construídas sequências espaço-temporais para o treinamento do modelo. Cada amostra é composta por cinco imagens consecutivas do radar como entrada e cinco passos futuros de precipitação observada como alvo. O modelo principal adotado é a arquitetura STConvS2S-C, treinada com uma função de perda mascarada, de modo que o erro seja calculado apenas nos pontos onde há observação das estações. Por fim, o modelo é avaliado no conjunto de teste por meio de métricas globais, por horizonte de previsão e por faixas de intensidade de precipitação. Modelos de referência, como persistência e Random Forest local, são utilizados posteriormente no capítulo de experimentos para comparação com a abordagem espaço-temporal proposta.

4.3 COLETA E ORGANIZAÇÃO DOS DADOS

A construção do conjunto de dados utilizado neste trabalho envolve a integração de duas fontes principais de observação: as imagens do Radar Meteorológico do Sumaré e os registros pluviométricos das estações de superfície do sistema WebSirene. Essa combinação permite explorar a complementaridade entre as duas fontes: o radar fornece uma representação espacial contínua dos sistemas precipitantes, enquanto as estações registram medições diretas de precipitação em superfície em pontos específicos da região de estudo.




Figura 4.1: Fluxo geral da metodologia utilizada para previsão de precipitação, destacando as principais etapas do processo, desde a coleta e organização dos dados até o treinamento do modelo espaço-temporal STConvS2S, sua avaliação e a comparação com modelos de referência.

O Radar Meteorológico da Prefeitura do Rio de Janeiro, instalado no Morro do Sumaré, fornece imagens em formato PNG com resolução temporal de 2 minutos. A Figura 4.2 apresenta um exemplo de sobreposição entre uma imagem de refletividade do Radar do Sumaré e uma base cartográfica, permitindo visualizar a área aproximada de cobertura do radar e sua posição em relação à Região Metropolitana do Rio de Janeiro. As imagens possuem resolução espacial aproximada de 500 metros, representando o campo de refletividade (dBZ) com uma paleta de cores que indica diferentes intensidades de chuva, tons de verde associados a chuva fraca, amarelo e laranja a chuva moderada e vermelho/rosa a chuva forte ou muito forte. A Figura 4.3 ilustra um exemplo dessas imagens. Os dados foram organizados por ano, mês e dia, facilitando o acesso e a indexação durante o processamento. Cada arquivo segue o padrão: YYYY_MM_DD_HH_MM.png. Como, por exemplo, 2024_01_02_00_18.png, o que permite identificar diretamente o instante temporal correspondente a cada imagem.

As estações do sistema WebSirene utilizadas neste trabalho estão distribuídas dentro da área de cobertura do Radar do Sumaré, o que permite associar de forma direta




Figura 4.3: Exemplo de imagem do Radar Meteorológico do Sumaré, mostrando o campo de refletividade em dBZ. As cores indicam diferentes intensidades de precipitação: verde para chuva fraca, amarelo e laranja para chuva moderada e vermelho/rosa para chuva forte a muito forte. Fonte: (AlertaRio).

RioNowCast tem como objetivo o desenvolvimento de métodos de previsão imediata de precipitação, e o conjunto de dados utilizado neste trabalho contribui para a construção e avaliação de modelos espaço-temporais baseados em radar.

4.4 PRÉ-PROCESSAMENTO E CONTROLE DE QUALIDADE

Após a etapa de coleta e organização dos dados, foi realizado um conjunto de procedimentos de pré-processamento com o objetivo de garantir a consistência temporal dos dados, reduzir o custo computacional do treinamento e aumentar a confiabilidade das observações utilizadas como alvo do modelo.

Inicialmente, as imagens do Radar Meteorológico do Sumaré, originalmente disponibilizadas com resolução temporal de aproximadamente 2 minutos, foram agregadas em intervalos de 15 minutos. Para cada intervalo, foi utilizada a composição por máximo valor observado, preservando os núcleos de maior intensidade presentes nas imagens e compatibilizando a resolução temporal do radar com a resolução das medições pluviométricas do sistema WebSirene.

As imagens agregadas foram posteriormente redimensionadas para uma grade regular de 256×256 pixels. Essa redução da resolução espacial foi adotada para tornar viável o treinamento do modelo espaço-temporal em termos de armazenamento, memória e tempo de processamento, uma vez que a utilização das imagens em sua resolução original demandaria custo computacional significativamente maior. Embora esse redimen-

sionamento possa reduzir detalhes espaciais de pequena escala, ele preserva a estrutura geral dos sistemas precipitantes, como localização, extensão e organização dos núcleos de chuva, considerados suficientes para esta primeira avaliação do pipeline espaço-temporal.

Em seguida, foi realizado o alinhamento temporal entre as imagens de radar e os registros das estações pluviométricas. Como ambas as fontes passaram a compartilhar a mesma resolução temporal de 15 minutos, cada observação de precipitação pôde ser associada diretamente ao instante correspondente da sequência de radar.

Também foi aplicado um procedimento de controle de qualidade aos dados pluviométricos. Durante a análise exploratória dos registros do sistema WebSirene, foram identificadas observações com valores excepcionalmente elevados de precipitação acumulada em 15 minutos. Considerando que valores superiores a 50 mm/15min representam acumulados muito extremos e podem estar associados tanto a eventos meteorológicos raros quanto a falhas instrumentais, erros de transmissão ou inconsistências nos registros, optou-se por removê-los do conjunto de dados.

Essa decisão foi adotada de forma conservadora, com o objetivo de reduzir a influência de observações potencialmente espúrias sobre o treinamento e a avaliação do modelo. No entanto, reconhece-se que esse limiar incide justamente sobre a faixa de precipitação mais severa, que é relevante para aplicações de alerta. Assim, a remoção desses valores constitui uma limitação metodológica deste trabalho. Uma análise mais aprofundada, envolvendo auditoria manual dos eventos extremos, comparação com outras redes pluviométricas ou experimentos de sensibilidade com e sem esse filtro, é indicada como trabalho futuro.

Além do controle de qualidade, a variável de precipitação utilizada como alvo foi transformada por meio de $\log(1 + x)$, após a remoção dos valores inconsistentes. Essa transformação foi aplicada aos alvos utilizados no treinamento, sendo posteriormente invertida na etapa de avaliação para que as métricas e os mapas fossem calculados em mm/15min.

Ao final dessa etapa, obteve-se um conjunto de dados temporalmente sincronizado, espacialmente compatível e submetido a procedimentos básicos de controle de qualidade, servindo como base para a construção das sequências espaço-temporais utilizadas no treinamento do modelo STConvS2S.

4.5 CONSTRUÇÃO DAS SEQUÊNCIAS ESPAÇO-TEMPORAIS

Após a etapa de pré-processamento, os dados foram organizados em sequências espaço-temporais adequadas ao treinamento da arquitetura STConvS2S. Como o objetivo do modelo é realizar previsão imediata de precipitação (*nowcasting*), cada amostra foi construída a partir de uma janela temporal contendo observações passadas do radar e observações futuras de precipitação em superfície.

Para cada instante de referência t , foram utilizadas as cinco imagens mais recentes do radar como entrada do modelo. Considerando a resolução temporal de 15 minutos adotada neste trabalho, cada sequência de entrada representa uma janela temporal de 75 minutos de observações atmosféricas. Dessa forma, a entrada é definida como:

$$\mathbf{X} = [X_{t-4}, X_{t-3}, X_{t-2}, X_{t-1}, X_t]$$

em que cada X_t corresponde a uma imagem RGB do Radar Meteorológico do Sumaré com resolução espacial de 256×256 pixels.

A saída desejada do modelo é composta pelos cinco instantes subsequentes de precipitação observada em superfície, definidos por:

$$\mathbf{Y} = [Y_{t+1}, Y_{t+2}, Y_{t+3}, Y_{t+4}, Y_{t+5}]$$

onde cada elemento representa a precipitação acumulada em 15 minutos observada pelas estações pluviométricas do sistema WebSirene.

Durante a construção do conjunto de dados, foi utilizado um deslocamento temporal de cinco intervalos entre amostras consecutivas. Essa estratégia reduz a sobreposição entre sequências adjacentes e diminui a redundância temporal presente nos dados, contribuindo para uma utilização mais eficiente dos recursos computacionais disponíveis.

Além disso, a utilização de cinco quadros de entrada fornece ao modelo uma janela de 75 minutos de observações anteriores, permitindo representar a evolução recente dos sistemas precipitantes, enquanto os cinco passos de saída correspondem aos 75 minutos seguintes de previsão. Reconhece-se, entretanto, que diferentes tamanhos de janela e valores de *stride* podem influenciar a capacidade do modelo de capturar a evolução das tempestades, sendo essa análise indicada para trabalhos futuros.

Ao final desse processo, cada amostra passa a representar uma sequência espaço-temporal composta por cinco imagens consecutivas de radar como entrada e cinco campos futuros de precipitação observada como saída, formando a estrutura utilizada no treinamento e avaliação do modelo STConvS2S.

4.6 CONSTRUÇÃO DE ALVOS ESPARSOS COM MÁSCARA DE OBSERVAÇÃO

Um dos principais desafios para o treinamento de modelos espaço-temporais de previsão de precipitação está relacionado à diferença de representação espacial entre as fontes de dados disponíveis. Enquanto as imagens do Radar Meteorológico do Sumaré são organizadas em uma grade regular, os pluviômetros do sistema WebSirene correspondem a observações pontuais distribuídas irregularmente pela região de interesse. Dessa forma, não há uma medida observada de precipitação para todos os pixels da imagem de radar, mas apenas para os pontos nos quais há estações de superfície instaladas.

Para lidar com essa diferença, este trabalho propõe a construção de um campo de precipitação esparsa, com a mesma resolução espacial da grade do radar. Para cada instante de tempo t , é criada uma matriz $Y_t \in \mathbb{R}^{H \times W}$, em que H e W representam, respectivamente, a altura e a largura da imagem do radar. Os pixels correspondentes às localizações das estações são preenchidos com os valores de precipitação observados em superfície, enquanto os demais pixels permanecem sem observação direta.

Além do campo de precipitação Y_t , é construída uma máscara binária de observação $M_t \in \{0, 1\}^{H \times W}$, definida como:

$$M_t(i, j) = \begin{cases} 1, & \text{se existe uma estação associada ao pixel } (i, j) \text{ no instante } t, \\ 0, & \text{caso contrário.} \end{cases}$$

Assim, o modelo pode produzir uma estimativa de precipitação para toda a grade espacial, mas a função de perda é calculada apenas nos pontos em que há observação pluviométrica disponível. Essa estratégia evita a necessidade de interpolar artificialmente a precipitação para regiões sem estações e preserva a natureza observacional dos dados de superfície.

Considerando uma previsão $\hat{Y}_t$ gerada pelo modelo e o campo observado Y_t , a função de perda utilizada no treinamento é definida como um erro absoluto médio mascarado:

$$\mathcal{L}_{\text{mask}} = \frac{\sum_t \sum_{i=1}^H \sum_{j=1}^W M_t(i, j) |\hat{Y}_t(i, j) - Y_t(i, j)|}{\sum_t \sum_{i=1}^H \sum_{j=1}^W M_t(i, j)}.$$

Dessa forma, apenas os pixels associados a pluviômetros contribuem para o treinamento do modelo. Os demais pixels, embora recebam previsões, não são utilizados diretamente no cálculo do erro por não possuírem valor observado de referência.

No contexto de modelos sequência-para-sequência, como o STConvS2S, essa ideia é estendida para janelas temporais. A entrada do modelo corresponde a uma sequência de imagens de radar:

$$X = [R_{t-k+1}, R_{t-k+2}, \dots, R_t],$$

em que k representa o tamanho da janela temporal de entrada. O alvo corresponde à sequência futura de campos esparsos de precipitação:

$$Y = [Y_{t+1}, Y_{t+2}, \dots, Y_{t+h}],$$

em que h representa o horizonte de previsão. Para cada campo futuro $Y_{t+\ell}$, também é construída uma máscara correspondente $M_{t+\ell}$, indicando quais pixels possuem

medições pluviométricas naquele instante.

Antes de serem armazenados como alvo do modelo, os valores de precipitação acumulada em 15 minutos foram transformados por meio de $\log(1+x)$, em que x representa a precipitação em mm/15min. Essa transformação foi aplicada aos campos Y_t , enquanto a máscara M_t permaneceu binária, indicando apenas a presença ou ausência de observação.

A principal vantagem dessa abordagem é permitir que o modelo aprenda a partir de observações reais de precipitação sem exigir que os dados de pluviômetros sejam convertidos previamente em um campo denso por interpolação. Assim, a grade regular do radar é preservada como entrada espaço-temporal, enquanto as estações de superfície fornecem supervisão pontual para orientar o aprendizado do modelo. Essa solução é particularmente adequada para regiões urbanas com distribuição irregular de pluviômetros, como a Região Metropolitana do Rio de Janeiro.

4.7 TREINAMENTO DO MODELO

O modelo principal adotado neste trabalho é a arquitetura STConvS2S, em sua variação STConvS2S-C. Essa arquitetura foi escolhida por permitir o processamento de sequências de imagens em grade regular, explorando simultaneamente padrões espaciais e temporais presentes nos campos de refletividade do radar.

A entrada do modelo é composta por sequências de cinco imagens RGB do Radar Meteorológico do Sumaré, previamente agregadas em intervalos de 15 minutos e redimensionadas para 256×256 pixels. A saída corresponde a cinco campos futuros de precipitação acumulada em 15 minutos, representados por alvos esparsos construídos a partir das medições das estações WebSirene e transformados para a escala $\log(1+x)$ durante o treinamento.

O treinamento foi realizado sobre a série histórica completa disponível na interseção entre as duas fontes de dados, compreendendo o período de 2012 a 2024. Foi utilizada uma função de perda baseada no erro absoluto médio mascarado. Assim, embora o modelo produza estimativas para toda a grade espacial, apenas os pixels associados a estações pluviométricas contribuem para o cálculo do erro e para a atualização dos pesos da rede. Essa estratégia evita penalizar o modelo em regiões onde não há observação direta de precipitação em superfície.

A divisão dos dados foi realizada de forma temporal, respeitando a ordem cronológica das amostras e evitando o embaralhamento aleatório entre treino, validação e teste. Após a construção das sequências espaço-temporais, as amostras foram ordenadas temporalmente e separadas em três subconjuntos contíguos: os primeiros 60% foram utilizados para treinamento, os 20% seguintes para validação e os 20% finais para teste. Essa estratégia foi adotada para reduzir o risco de vazamento temporal, uma vez que amostras próximas no tempo podem compartilhar imagens de radar e alvos futuros semelhantes.

Dessa forma, o conjunto de teste representa um período posterior ao utilizado no treinamento, aproximando a avaliação de um cenário real de previsão, no qual o modelo é treinado com dados passados e avaliado em instantes futuros ainda não observados.

Os hiperparâmetros de treinamento e demais configurações experimentais são apresentados no Capítulo 5, juntamente com os resultados obtidos. Além do modelo principal, foi considerado o baseline de persistência como referência quantitativa direta para a STConvS2S. O Random Forest local foi mantido como experimento preliminar de calibração pontual, sem comparação direta com a arquitetura espaço-temporal, devido às diferenças na configuração experimental.

4.8 AVALIAÇÃO DO MODELO

A avaliação do desempenho do modelo foi realizada exclusivamente sobre o conjunto de teste, preservando a distribuição original dos dados e mantendo as características observadas ao longo da série histórica. Como os alvos utilizados neste trabalho são campos esparsos de precipitação, as métricas foram calculadas apenas nos pixels associados às estações pluviométricas, conforme definido pelas máscaras de observação apresentadas na Seção 4.6.

Embora o modelo tenha sido treinado na escala transformada $\log(1 + x)$, todas as métricas e mapas apresentados neste trabalho foram calculados após a transformação inversa dos valores previstos e observados, retornando a precipitação para sua unidade nativa, mm/15min. Para fins de interpretação, as faixas de intensidade também são apresentadas em taxa horária equivalente (mm/h), obtida pela multiplicação dos valores em mm/15min por quatro. Dessa forma, as categorias de chuva fraca, moderada, forte e extrema permanecem compatíveis com a classificação meteorológica usual.

Inicialmente, a avaliação foi realizada de forma global, considerando todas as observações disponíveis no conjunto de teste. Para essa análise, foram utilizadas as métricas raiz do erro quadrático médio (RMSE), erro absoluto médio (MAE) e viés (*Bias*), permitindo quantificar tanto a magnitude dos erros quanto possíveis tendências sistemáticas de superestimação ou subestimação por parte do modelo.

Além da avaliação global, também foi realizada uma análise por horizonte de previsão, permitindo avaliar separadamente o desempenho do modelo para cada um dos cinco passos futuros previstos pela arquitetura STConvS2S. Essa análise possibilita verificar como a qualidade das previsões varia à medida que o horizonte temporal aumenta.

Por fim, foi realizada uma avaliação estratificada por intensidade de precipitação. Os valores observados foram agrupados em quatro categorias: chuva fraca (inferior a 1,25 mm/15min; equivalente a 5 mm/h), chuva moderada (entre 1,25 e 6,25 mm/15min; equivalente a 5–25 mm/h), chuva forte (entre 6,25 e 12,5 mm/15min; equivalente a 25–50 mm/h) e chuva extrema (superior a 12,5 mm/15min; equivalente a valores superiores a

50 mm/h). Essa abordagem permite analisar o comportamento do modelo em diferentes regimes de precipitação, mantendo a unidade nativa dos dados e apresentando a taxa horária apenas como referência equivalente para interpretação.

Os resultados obtidos por meio dessas métricas servem como base para a avaliação da arquitetura STConvS2S e para sua comparação quantitativa direta com o baseline de persistência. O experimento com Random Forest local e a análise detalhada dos resultados são apresentados no Capítulo 5.

As métricas utilizadas neste trabalho avaliam diferentes aspectos do desempenho das previsões. O RMSE atribui maior peso a erros de maior magnitude, o MAE fornece uma medida média do erro absoluto e o viés permite identificar tendências sistemáticas de superestimação ou subestimação. A Tabela 4.1 apresenta um resumo dessas métricas e suas respectivas formulações matemáticas.

Tabela 4.1: Resumo das métricas de desempenho utilizadas para avaliar o modelo.

Métrica	Descrição
RMSE	Raiz do Erro Quadrático Médio (<i>Root Mean Squared Error</i>), que representa a raiz quadrada da média dos erros quadráticos entre os valores previstos e os valores observados.
$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$	
MAE	Erro Absoluto Médio (<i>Mean Absolute Error</i>), que representa a média das diferenças absolutas entre os valores previstos e os valores observados.
$MAE = \frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	
Viés	Diferença média entre as previsões e os valores reais, indicando tendência sistemática de superestimação ou subestimação do modelo.
$\text{Viés} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)$	

4.9 ABORDAGENS DE REFERÊNCIA

Para contextualizar o desempenho da arquitetura STConvS2S, foram consideradas duas abordagens de referência: o baseline de persistência e o Random Forest local.

A persistência representa uma das abordagens mais simples para *nowcasting*, assumindo que as condições observadas no instante atual permanecerão inalteradas nos instantes futuros. Nesse caso, a precipitação observada no último instante disponível é utilizada diretamente como previsão para os horizontes subsequentes. Essa abordagem foi utilizada como baseline quantitativo direto, pois pode ser avaliada no mesmo conjunto de teste da STConvS2S, considerando os mesmos instantes, estações e horizontes de previsão. Apesar de sua simplicidade, esse método constitui uma referência importante, pois apresenta desempenho competitivo em horizontes curtos de previsão e é frequentemente utilizado como baseline em estudos de *nowcasting*.

Além da persistência, foi considerado o Random Forest Regressor como experimento preliminar de calibração pontual baseado em aprendizado de máquina. Diferentemente da arquitetura STConvS2S, que explora relações espaciais e temporais presentes nas sequências de imagens de radar, o Random Forest local realiza estimativas a partir de atributos extraídos no pixel correspondente a cada estação pluviométrica, de forma independente. Dessa maneira, essa abordagem não incorpora diretamente a estrutura espacial completa dos sistemas precipitantes. Por ter sido avaliada em uma configuração experimental distinta, seus resultados não são comparados diretamente aos da STConvS2S, mas são utilizados para discutir as limitações de abordagens locais.

Os detalhes de implementação dessas abordagens e os resultados obtidos são apresentados no Capítulo 5.

4.10 DISCUSSÃO

A metodologia proposta neste trabalho foi desenvolvida para explorar a capacidade de modelos espaço-temporais em problemas de previsão imediata de precipitação a partir de dados de radar meteorológico. A utilização conjunta das imagens do Radar Meteorológico do Sumaré e das medições pluviométricas do sistema WebSirene permitiu construir um conjunto de dados que combina informações sobre a evolução espacial dos sistemas precipitantes e observações diretas de chuva em superfície.

Uma das principais contribuições metodológicas consiste na construção de alvos esparsos de precipitação acompanhados por máscaras de observação. Essa abordagem possibilita utilizar diretamente as medições das estações pluviométricas sem a necessidade de interpolar artificialmente os dados para toda a grade espacial do radar. Dessa forma, o treinamento do modelo é realizado apenas nos locais onde existem observações confiáveis de precipitação, preservando a natureza observacional dos dados.

Outro aspecto relevante é a utilização de sequências temporais de imagens de

radar como entrada do modelo. Diferentemente de abordagens tradicionais baseadas em observações pontuais ou atributos extraídos individualmente, a arquitetura STConvS2S permite explorar simultaneamente padrões espaciais e temporais associados à formação, deslocamento e dissipação dos sistemas precipitantes. Essa característica é particularmente importante em aplicações de nowcasting, nas quais a evolução temporal dos fenômenos meteorológicos desempenha papel fundamental na qualidade das previsões.

Apesar das vantagens apresentadas, algumas limitações devem ser consideradas. A distribuição espacial das estações pluviométricas é irregular, resultando em regiões da grade do radar com menor quantidade de observações disponíveis para supervisão do modelo. Além disso, eventos de precipitação intensa ocorrem com frequência significativamente menor do que eventos de chuva fraca ou ausência de chuva, gerando um desbalanceamento natural dos dados que tende a dificultar a aprendizagem dos padrões associados aos eventos extremos.

Por fim, destaca-se que a metodologia proposta estabelece uma estrutura flexível para futuras extensões, incluindo a incorporação de novas fontes de informação meteorológica, diferentes arquiteturas de aprendizado profundo e horizontes de previsão mais longos. Essas possibilidades podem contribuir para o aprimoramento contínuo de sistemas de previsão imediata de precipitação voltados ao monitoramento e à mitigação de riscos hidrometeorológicos.

5 EXPERIMENTOS E RESULTADOS

Neste capítulo são apresentados os experimentos e resultados obtidos neste trabalho, com foco na implementação e avaliação da arquitetura STConvS2S para previsão imediata de precipitação a partir de imagens do Radar Meteorológico do Sumaré e medições pluviométricas do sistema WebSirene. A Seção 5.1 apresenta a análise exploratória dos dados utilizados nos experimentos. A Seção 5.2 descreve os modelos de referência e a estratégia de comparação adotada. A Seção 5.3 apresenta os resultados do Random Forest local, tratado como experimento preliminar de calibração local. A Seção 5.4 descreve a configuração experimental da arquitetura STConvS2S. A Seção 5.5 apresenta seus resultados no conjunto de teste. A comparação direta entre a STConvS2S e o baseline de persistência é apresentada na Seção 5.6. A Seção 5.7 apresenta as visualizações espaciais das estimativas. A Seção 5.8 discute os principais resultados e limitações observadas.

5.1 ANÁLISE EXPLORATÓRIA DOS DADOS

Antes da etapa de treinamento dos algoritmos de aprendizado, foi realizada uma análise exploratória dos dados com o objetivo de compreender o comportamento estatístico das variáveis utilizadas nos experimentos. Essa análise teve como foco inicial o conjunto utilizado no experimento preliminar de calibração local com Random Forest, utilizando os dados associados à Estação 14 do sistema WebSirene como estudo de caso. Embora o experimento principal deste trabalho utilize a série histórica completa e sequências espaço-temporais de radar, essa análise pontual auxilia na interpretação da relação entre refletividade, precipitação observada e variáveis auxiliares, como a elevação do terreno.

Nesta etapa exploratória, a variável de precipitação foi analisada em sua unidade original, como precipitação acumulada em 15 minutos. A conversão para taxa horária equivalente em (mm/h) foi utilizada posteriormente apenas na apresentação das métricas de desempenho, das faixas de intensidade e dos mapas de precipitação estimada.

Inicialmente, foi realizada uma inspeção da estrutura do conjunto de dados por meio das funções `info()` e `describe()` da biblioteca *pandas*. Observou-se que o conjunto de calibração contém aproximadamente 295 mil registros, sem valores ausentes nas variáveis analisadas, incluindo os canais de refletividade do radar (R, G e B), a elevação do terreno e a precipitação acumulada em 15 minutos (m15). As estatísticas descritivas indicam forte assimetria nas distribuições, com predominância de valores iguais ou próximos de zero, especialmente para a variável de precipitação.

5.1.1 Distribuição da precipitação observada

A distribuição da precipitação observada em superfície é apresentada na Figura 5.1. Nota-se que a maior parte das amostras corresponde à ausência de chuva

ou a valores muito baixos, enquanto eventos de chuva moderada e intensa ocorrem com frequência significativamente menor. A visualização em escala logarítmica evidencia a presença de poucos eventos extremos, confirmando o forte desbalanceamento da variável alvo, característica comum em problemas de estimativa de precipitação convectiva.




Figura 5.1: Distribuição da precipitação observada em superfície (m15) para a Estação 14, apresentada em escala logarítmica de frequência.

5.1.2 Diagnóstico de desbalanceamento

O desbalanceamento da variável alvo é reforçado pela análise binária da ocorrência de chuva, apresentada na Figura 5.2. Observa-se uma predominância expressiva da classe associada à ausência de precipitação em relação à classe com ocorrência de chuva. Esse comportamento ajuda a explicar a dificuldade dos algoritmos de aprendizado em representar eventos de maior intensidade, que ocorrem com frequência muito menor no conjunto de dados.

5.1.3 Distribuição da refletividade do radar

A Figura 5.3 apresenta as distribuições dos valores dos canais R, G e B extraídos das imagens do Radar Meteorológico do Sumaré. Em todos os canais, predominam valores baixos de intensidade, associados a regiões sem eco ou com refletividade fraca, enquanto valores elevados, relacionados a núcleos convectivos mais intensos, ocorrem com menor frequência. Esse comportamento é coerente com a distribuição observada da precipitação em superfície.

5.1.4 Distribuição do relevo

A variável de elevação do terreno, obtida a partir do Modelo Digital de Elevação (DEM), foi incorporada ao conjunto de calibração como uma característica espacial




Figura 5.2: Distribuição binária da ocorrência de precipitação para a Estação 14, indicando o desbalanceamento entre eventos de chuva e não-chuva.




Figura 5.3: Distribuição dos valores de refletividade do radar nos canais R, G e B para o conjunto de calibração da Estação 14.

associada à localização de cada estação. Para uma estação individual, como a Estação 14 considerada neste experimento, a elevação assume um valor constante, uma vez que corresponde à altitude fixa do ponto onde o sensor está instalado, repetindo-se em todas as observações temporais dessa estação.

Nesse contexto, a elevação do terreno atua como uma informação espacial fixa por estação, utilizada para avaliar possíveis efeitos orográficos na relação entre refletividade observada pelo radar e precipitação registrada em superfície. Como essa variável não varia temporalmente dentro de uma mesma estação, sua contribuição tende a ser limitada em análises pontuais, mas pode ser útil para caracterizar diferenças espaciais entre estações.

5.1.5 Relação entre radar, relevo e precipitação

A matriz de correlação entre as variáveis analisadas é apresentada na Figura 5.4. Observa-se forte correlação entre os canais R, G e B, como esperado, uma vez que todos representam diferentes componentes da mesma informação de refletividade do radar. A correlação entre os canais de refletividade e a precipitação observada é positiva, porém fraca, indicando que a relação entre refletividade e chuva em superfície é predominantemente não linear. A variável de elevação não apresenta correlação direta relevante com a precipitação, sugerindo que seu papel é indireto e dependente do contexto espacial e atmosférico.




Figura 5.4: Matriz de correlação entre os canais de refletividade do radar (R, G e B), a elevação do terreno e a precipitação observada (m15) para a Estação 14.

5.1.6 Considerações para a modelagem

De forma geral, a análise exploratória evidencia a complexidade do problema de estimativa e previsão de precipitação a partir de dados de radar, destacando baixa predominância das chuvas intensas na variável alvo, a predominância de baixos valores de refletividade e a natureza não linear das relações envolvidas. Esses aspectos ajudam a interpretar tanto os resultados do experimento preliminar com Random Forest local quanto as dificuldades observadas posteriormente na arquitetura STConvS2S, especialmente na previsão de eventos moderados, fortes e extremos.

5.2 MODELOS DE REFERÊNCIA E ESTRATÉGIA DE COMPARAÇÃO

Para avaliar adequadamente o desempenho do modelo espaço-temporal baseado na arquitetura STConvS2S, torna-se necessário compará-lo com modelos de referência mais simples. Essa comparação permite verificar se a arquitetura proposta é capaz de produzir ganhos em relação a abordagens que não modelam explicitamente a estrutura espaço-temporal dos campos de refletividade do radar.

Foi adotada uma estratégia de comparação baseada em dois tipos de referência. O primeiro é o baseline de persistência, utilizado como comparação quantitativa direta com a STConvS2S. O segundo é o Random Forest local, considerado como experimento preliminar de calibração pontual entre refletividade do radar e precipitação observada em superfície.

A persistência foi utilizada como baseline principal por permitir avaliação no mesmo conjunto de teste da STConvS2S, considerando os mesmos instantes, estações e horizontes de previsão. Dessa forma, seus resultados são diretamente comparáveis aos obtidos pela arquitetura espaço-temporal. Já o Random Forest local foi avaliado em uma configuração experimental distinta, restrita a um conjunto reduzido de estações e baseada em atributos extraídos no pixel correspondente à localização de cada estação. Por esse motivo, seus resultados não são comparados diretamente com os da STConvS2S, mas são mantidos no capítulo como referência metodológica para discutir as limitações de abordagens pontuais.

5.2.1 Baseline de Persistência

O primeiro modelo de referência adotado é a persistência. Em problemas de nowcasting, esse baseline assume que a condição observada no instante atual se mantém nos instantes futuros. Assim, para uma estação s , a previsão de precipitação para um horizonte futuro h é dada por:

$$\hat{P}_s(t + h) = P_s(t),$$

em que $P_s(t)$ representa a precipitação observada na estação s no instante t , e $\hat{P}_s(t + h)$ representa a previsão para o instante $t + h$.

Embora simples, esse baseline é importante porque estabelece uma referência mínima para avaliar modelos de previsão imediata. Em horizontes muito curtos, a persistência pode apresentar desempenho competitivo, especialmente quando os sistemas precipitantes evoluem lentamente. Por outro lado, em situações de chuva convectiva, caracterizadas por rápida formação, intensificação ou dissipação, espera-se que modelos capazes de explorar a evolução espacial e temporal dos campos de radar superem esse comportamento persistente.

5.2.2 Experimento Preliminar com Random Forest Local

Além da persistência, foi realizado um experimento preliminar utilizando Random Forest local. Nesse caso, foram treinados modelos supervisionados pontuais para estações específicas, utilizando atributos extraídos no pixel do radar correspondente à posição geográfica da estação.

Para uma estação s , o problema é formulado como uma tarefa de regressão:

$$X_s(t) \rightarrow P_s(t + h),$$

em que $X_s(t)$ representa o vetor de atributos extraído no instante t , e $P_s(t + h)$ é a precipitação observada na estação s em um horizonte futuro h . O vetor de entrada pode incluir os valores dos canais RGB do radar no pixel da estação, valores defasados desses canais em instantes anteriores e variáveis estáticas, como a altitude derivada do Modelo Digital de Elevação (DEM).

O Random Forest local é utilizado neste trabalho como referência metodológica para avaliar uma abordagem pontual, baseada apenas nas informações do pixel correspondente à estação. Diferentemente da STConvS2S, essa abordagem não utiliza explicitamente a estrutura espacial completa das imagens de radar nem modela a evolução espaço-temporal dos sistemas precipitantes. Assim, seus resultados são discutidos separadamente e não são utilizados nas tabelas principais de comparação direta com a STConvS2S.

5.2.3 Comparação com o Modelo Espaço-Temporal

A comparação quantitativa direta da STConvS2S é realizada apenas com o baseline de persistência. Ambos são avaliados no mesmo conjunto de teste, considerando os mesmos horizontes futuros, os mesmos instantes e os mesmos pixels associados às estações WebSirene. Essa estratégia garante que a comparação seja metodologicamente consistente.

Embora a STConvS2S produza estimativas de precipitação para toda a grade espacial do radar, a avaliação quantitativa é feita apenas nos pixels onde há observação pluviométrica disponível. A persistência é calculada nesses mesmos pontos, utilizando a precipitação observada no último instante da sequência de entrada como previsão para os cinco passos futuros.

Logo, para cada estação s , horizonte de previsão h e instante de teste t , são comparadas duas estimativas:

- a previsão do baseline de persistência;
- a previsão da STConvS2S extraída no pixel correspondente à estação.

Dessa forma, a avaliação busca verificar se a arquitetura espaço-temporal é capaz de superar a hipótese simples de continuidade temporal da precipitação observada. O

experimento com Random Forest local, por sua vez, é utilizado apenas como referência complementar para discutir as limitações de abordagens pontuais.

5.2.4 Métricas de Avaliação dos Baselines

A avaliação da STConvS2S e da persistência foi realizada utilizando métricas de erro e de viés, calculadas de forma global e por nível de precipitação. As principais métricas consideradas são o erro absoluto médio (MAE), a raiz do erro quadrático médio (RMSE) e o viés médio:

$$MAE = \frac{1}{n} \sum_{i=1}^n \left| \hat{P}_i - P_i \right|,$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n \left(\hat{P}_i - P_i \right)^2},$$

$$Bias = \frac{1}{n} \sum_{i=1}^n \left(\hat{P}_i - P_i \right).$$

Além da avaliação global, os resultados são analisados por faixas de intensidade de precipitação, permitindo verificar o comportamento dos modelos em diferentes regimes de chuva. As faixas consideradas são:

Chuva fraca:	$0 \leq P < 1,25 \text{ mm/15min}$ (equivalente a $< 5 \text{ mm/h}$),
Chuva moderada:	$1,25 \leq P < 6,25 \text{ mm/15min}$ (equivalente a $5\text{--}25 \text{ mm/h}$),
Chuva forte:	$6,25 \leq P < 12,5 \text{ mm/15min}$ (equivalente a $25\text{--}50 \text{ mm/h}$),
Chuva extrema:	$P \geq 12,5 \text{ mm/15min}$ (equivalente a $> 50 \text{ mm/h}$).

5.2.5 Síntese da Estratégia de Comparação

A Tabela 5.1 resume o papel de cada abordagem considerada nos experimentos deste trabalho.

Essa estratégia de comparação fornece uma base experimental mais consistente para interpretar os resultados da STConvS2S. A persistência permite avaliar diretamente se a arquitetura espaço-temporal agrega informação em relação à hipótese simples de continuidade temporal da precipitação observada. O Random Forest local, por sua vez, é mantido como experimento preliminar de calibração pontual, contribuindo para a discussão sobre as limitações de abordagens que utilizam apenas informações locais do radar, sem explorar explicitamente a estrutura espacial e temporal dos sistemas precipitantes.

Tabela 5.1: Abordagens consideradas na comparação experimental.

Abordagem	Entrada	Objetivo da comparação
Persistência	Precipitação observada no instante atual	Avaliar se os modelos superam a hipótese simples de continuidade temporal da chuva.
Random Forest local	RGB do pixel da estação, valores defasados e altitude	Experimento preliminar de calibração local, sem comparação quantitativa direta com a STConvS2S.
STConvS2S	Sequência de imagens de radar em grade regular	Avaliar o ganho obtido por uma arquitetura capaz de modelar dependências espaciais e temporais.

5.3 EXPERIMENTO PRELIMINAR DE CALIBRAÇÃO LOCAL

Nesta seção são apresentados os resultados obtidos no experimento preliminar de calibração local com Random Forest. Esse experimento foi conduzido em uma configuração pontual, considerando cinco estações específicas do sistema WebSirene e atributos extraídos do pixel do radar correspondente a cada estação. Portanto, os resultados apresentados nesta seção não são comparados diretamente aos obtidos pela arquitetura STConvS2S, que foi treinada e avaliada na série histórica completa, com todas as estações disponíveis e com sequências espaço-temporais de imagens de radar. Ainda assim, essa análise é mantida por permitir discutir as limitações de abordagens locais e pontuais na estimativa da precipitação.

Em seguida, é discutido o impacto da inclusão da variável de elevação no desempenho desse algoritmo. Esses resultados servem como base para avaliar as limitações de abordagens pontuais e justificar a adoção de uma arquitetura espaço-temporal.

5.3.1 Resultados do Random Forest Local

O desempenho global do modelo Random Forest foi avaliado por meio das métricas Coeficiente de Determinação (R^2), Erro Absoluto Médio (MAE) e viés. Embora o modelo tenha sido treinado utilizando a variável (m15), correspondente à precipitação acumulada em 15 minutos, os resultados do Random Forest são apresentados em mm/h equivalente para facilitar a interpretação. De forma geral, os resultados indicaram valores de MAE próximos de 1 mm/h equivalente para as cinco estações analisadas. Esse comportamento reflete a capacidade do modelo em estimar adequadamente os casos mais frequentes do conjunto de dados, dominados por ausência de chuva ou precipitação de baixa intensidade. Por outro lado, os valores de R^2 apresentaram-se próximos de zero ou negativos em todas as estações, indicando que o modelo possui dificuldade em explicar a

variabilidade total da precipitação observada. Esse resultado está fortemente associado ao desbalanceamento do conjunto de dados, dominado por casos de chuva fraca ou ausência de precipitação, além da elevada dispersão presente nos eventos de maior intensidade. A Tabela 5.2 apresenta um resumo dessas métricas para cada estação avaliada.

Tabela 5.2: Desempenho global do modelo Random Forest para as cinco estações analisadas.

Estação	R^2	MAE (mm/h equiv.)	Viés (mm/h equiv.)
10	-0.005	1.11	0.78
11	-0.468	1.02	0.86
12	-0.211	1.08	0.85
13	-0.153	1.07	0.83
14	-0.346	1.01	0.81

5.3.2 Análise por Intensidade de Precipitação

Além da avaliação global, o desempenho do Random Forest local foi analisado considerando diferentes faixas de intensidade de precipitação. Observou-se que a maioria das amostras pertence à classe de chuva fraca (0-5 mm/h equivalente), enquanto os eventos de chuva moderada (5-25 mm/h equivalente), forte (25-50 mm/h equivalente) e extrema (> 50 mm/h equivalente) são pouco frequentes. Para a classe de chuva fraca, o modelo apresentou erros médios reduzidos, embora com valores de R^2 negativos, resultado esperado devido à baixa variabilidade interna dessa faixa. Nas faixas de chuva moderada e forte, verificou-se aumento expressivo do MAE e viés negativo, indicando tendência do modelo em subestimar a intensidade da precipitação nesses cenários. Esse comportamento é exemplificado na Tabela 5.3, que apresenta os resultados estratificados por faixa de intensidade para a Estação 12. No caso da chuva extrema, o número de amostras foi extremamente reduzido, o que inviabiliza uma avaliação estatística robusta e resulta em métricas indefinidas ou pouco representativas.

Tabela 5.3: Desempenho do modelo Random Forest para a Estação 12, estratificado por faixa de intensidade de precipitação.

Faixa de precipitação	R^2	MAE (mm/h equiv.)	Viés (mm/h equiv.)
Chuva fraca (0-5 mm/h)	-9.163	0.99	0.95
Chuva moderada (5-25 mm/h)	-3.137	9.15	-9.10
Chuva forte (25-50 mm/h)	-21.637	34.39	-34.39
Chuva extrema (> 50 mm/h)	-2.795	89.42	-89.42

Apesar das limitações quantitativas, especialmente para eventos de maior intensidade, o Random Forest local demonstrou comportamento consistente ao produzir estimativas espacialmente coerentes quando aplicado a todos os pixels da imagem de radar.

A análise qualitativa das estimativas espaciais é apresentada posteriormente por meio de mapas de precipitação e comparações com as medições das estações.

5.3.3 Impacto da Elevação no Random Forest Local

A inclusão da variável de elevação do relevo teve como objetivo investigar possíveis ganhos no desempenho do modelo, especialmente em regiões onde efeitos orográficos podem influenciar a distribuição espacial da precipitação. Para isso, foram comparados dois conjuntos de experimentos para cada estação: um utilizando apenas as variáveis de refletividade do radar (R, G e B) e outro incorporando adicionalmente a elevação do terreno extraída do Modelo Digital de Elevação.

A comparação entre os modelos com e sem relevo indicou que a inclusão da variável de elevação não resultou em melhorias significativas nas métricas globais de desempenho, como R^2 e MAE. Em todas as cinco estações analisadas, as diferenças observadas entre as duas configurações foram pequenas e inconsistentes, sugerindo que o relevo, isoladamente, não foi suficiente para capturar variações adicionais relevantes na relação entre refletividade e precipitação.

Em áreas associadas a relevo mais acidentado, esperava-se que a elevação pudesse contribuir para uma melhor representação de efeitos orográficos. No entanto, os resultados não indicaram variações sistemáticas no desempenho do modelo nessas regiões, o que pode estar relacionado à baixa resolução temporal dos dados de precipitação observada, ao reduzido número de eventos intensos ou à predominância de chuvas fracas no conjunto de dados.

A análise da importância das variáveis no modelo Random Forest confirmou que as componentes de refletividade do radar permanecem como os principais fatores explicativos da precipitação estimada. A variável de elevação apresentou contribuição secundária, reforçando que, no contexto deste estudo, a informação fornecida pelo radar é dominante na estimativa da precipitação em superfície.

5.4 MODELO ESPAÇO-TEMPORAL COM STCONVS2S

O experimento principal deste trabalho foi realizado utilizando a arquitetura STConvS2S em sua configuração STConvS2S-C, proposta por Castro et al. 2021. O objetivo do modelo é realizar previsão imediata de precipitação a partir de sequências de imagens do Radar Meteorológico do Sumaré, explorando simultaneamente informações espaciais e temporais presentes nos campos de refletividade.

O conjunto de dados foi construído a partir da série histórica completa disponível entre 2012 e 2024, abrangendo aproximadamente treze anos de observações de radar e medições pluviométricas do sistema WebSirene. As subseções seguintes apresentam o processo de construção das sequências de entrada, a geração dos alvos mascarados utili-

zados durante o treinamento e a configuração experimental adotada para o treinamento da arquitetura STConvS2S-C.

5.4.1 Preparação das Sequências de Entrada

As entradas do modelo foram construídas a partir de sequências temporais de imagens do Radar Meteorológico do Sumaré. Inicialmente, as imagens originais, disponibilizadas a cada dois minutos, foram agregadas em intervalos de 15 minutos, compatibilizando sua resolução temporal com os dados pluviométricos das estações WebSirene.

Após a agregação temporal, as imagens foram redimensionadas para uma grade regular de 256×256 pixels. Essa redução de resolução foi adotada para diminuir os requisitos computacionais de armazenamento e processamento, tornando viável o treinamento da arquitetura espaço-temporal utilizando a série histórica completa disponível.

Cada amostra de entrada é composta por uma sequência de cinco imagens consecutivas do radar, correspondendo a uma janela temporal de observação. Como as imagens possuem três canais de cor (RGB), cada entrada apresenta dimensão $3 \times 5 \times 256 \times 256$, conforme observado durante a execução do treinamento.

Para a construção das amostras foi utilizado *stride* igual a 5, fazendo com que duas sequências consecutivas possuam menor sobreposição temporal. Ao final do processo foram geradas 45.666 amostras para treinamento, 15.222 para validação e 15.223 para teste.

5.4.2 Construção dos Alvos Mascarados

Os alvos utilizados no treinamento foram construídos a partir das observações pluviométricas das estações do sistema WebSirene. Como essas observações estão disponíveis apenas em pontos específicos do espaço, foi adotada a estratégia de campos esparsos de precipitação descrita no Capítulo 4.

Para cada sequência de entrada foram gerados cinco campos futuros de precipitação, correspondentes aos cinco passos temporais previstos pela arquitetura STConvS2S-C. Os valores observados foram inseridos apenas nos pixels associados às estações pluviométricas, enquanto os demais pixels permaneceram sem observação direta.

Adicionalmente, foi construída uma máscara binária de observação indicando os locais onde existem medições válidas. Essa máscara foi utilizada durante o treinamento para restringir o cálculo da função de perda apenas aos pixels associados às estações. Dessa forma, evitou-se a necessidade de interpolar artificialmente a precipitação para regiões sem observação direta.

As dimensões observadas durante a execução do experimento foram compatíveis com a configuração adotada, resultando em tensores de saída com dimensão $1 \times 5 \times 256 \times 256$, tanto para os campos de precipitação quanto para as máscaras de observação.

5.4.3 Configuração de Treinamento

Os experimentos foram executados em uma estação de trabalho com GPU NVIDIA RTX 5090, utilizando PyTorch com suporte a CUDA. O conjunto de dados foi dividido em três subconjuntos, sendo 60% destinado ao treinamento, 20% à validação e 20% ao teste.

O treinamento final da arquitetura STConvS2S-C foi realizado com tamanho de lote (*batch size*) igual a 8, número máximo de 10 épocas e mecanismo de *early stopping* configurado com paciência igual a 3 épocas. O alvo utilizado no treinamento correspondeu à precipitação acumulada em 15 minutos na escala $\log(1 + x)$.

A função de perda utilizada foi baseada em erro mascarado, calculado exclusivamente nos pixels associados às estações pluviométricas. Essa estratégia garante que apenas observações reais contribuam para a atualização dos pesos da rede neural.

Durante o treinamento, o melhor modelo foi selecionado automaticamente com base no desempenho observado no conjunto de validação. O processo foi interrompido na época 4 pelo critério de *early stopping*, sendo selecionado como melhor checkpoint o modelo obtido na época 1, com erro de validação igual a 0,1446. O tempo total de treinamento foi de aproximadamente 2 h 22 min.

Essa configuração teve caráter exploratório, buscando validar todo o pipeline de preparação dos dados, treinamento e avaliação da arquitetura STConvS2S-C. Assim, os resultados obtidos representam uma primeira avaliação experimental do modelo, servindo como base para investigações futuras envolvendo configurações de treinamento mais extensas e diferentes estratégias de validação.

5.5 RESULTADOS DO MODELO STCONVS2S

Nesta seção são apresentados os resultados obtidos pela arquitetura STConvS2S no conjunto de teste. A avaliação foi realizada considerando diferentes perspectivas de análise, incluindo o desempenho global para cada horizonte de previsão, o comportamento do modelo em diferentes faixas de intensidade de precipitação e a análise do viés das previsões.

5.5.1 Desempenho Global por Horizonte de Previsão

Após o treinamento da arquitetura STConvS2S-C, o desempenho foi avaliado utilizando o conjunto de teste. Como o modelo produz previsões para cinco passos temporais futuros, foram calculadas métricas separadamente para cada horizonte de previsão.

A Tabela 5.4 apresenta os valores de RMSE e MAE obtidos para cada um dos cinco horizontes previstos.

Os resultados apresentados na Tabela 5.4 mostram pequena variação dos erros entre os horizontes de previsão. O MAE permanece próximo de 0,04 mm/15min em

Tabela 5.4: Desempenho do modelo STConvS2S por horizonte de previsão.

Horizonte	RMSE	MAE	Viés
T+1	0.1416	0.0439	-0.0434
T+2	0.1360	0.0433	-0.0430
T+3	0.1372	0.0426	-0.0421
T+4	0.1339	0.0426	-0.0419
T+5	0.1364	0.0422	-0.0413

todos os passos futuros, enquanto o RMSE varia entre 0,1339 e 0,1416 mm/15min. Esse comportamento indica estabilidade temporal das previsões ao longo dos cinco horizontes avaliados.

Além da avaliação por horizonte, foram calculadas métricas globais considerando todas as observações do conjunto de teste. O modelo apresentou RMSE igual a 0,1533, MAE igual a 0,0429 e viés igual a -0,0423.

5.5.2 Desempenho por Intensidade de Precipitação

A Tabela 5.5 apresenta os resultados obtidos para as diferentes faixas de precipitação.

Tabela 5.5: Desempenho do modelo STConvS2S por faixa de intensidade de precipitação.

Faixa de precipitação	RMSE	MAE	Viés
Chuva fraca (<1,25 mm/15min; <5 mm/h equiv.)	0.1148	0.0219	-0.0212
Chuva moderada (1,25–6,25 mm/15min; 5–25 mm/h equiv.)	2.7701	2.4966	-2.4966
Chuva forte (6,25–12,5 mm/15min; 25–50 mm/h equiv.)	8.8016	8.6281	-8.6281
Chuva extrema (>12,5 mm/15min; >50 mm/h equiv.)	18.7495	17.9092	-17.9092

Observa-se forte desbalanceamento entre as faixas de precipitação, com 3.445.265 amostras na classe de chuva fraca, contra 26.807 na classe moderada, 2.739 na classe forte e 1.179 na classe extrema. Esse desbalanceamento ajuda a explicar o melhor desempenho da arquitetura em eventos de baixa intensidade e a maior dificuldade na previsão de eventos moderados, fortes e extremos, uma vez que esses casos ocorrem com frequência muito menor e, conseqüentemente, são menos representados durante o treinamento.

Esse desequilíbrio também influencia diretamente a interpretação das métricas globais. Como a classe de chuva fraca concentra a maior parte das amostras avaliadas, métricas agregadas como RMSE, MAE e viés tendem a refletir predominantemente o desempenho do modelo nesse regime de precipitação. Assim, bons resultados globais não implicam necessariamente bom desempenho em eventos moderados, fortes ou extremos, que são menos frequentes, porém mais relevantes do ponto de vista operacional.

5.5.3 Análise do Viés

O viés global obtido pelo modelo foi igual a -0.0423, indicando tendência geral de subestimativa da precipitação observada. Essa característica também é observada na análise por horizonte, na qual todos os passos futuros apresentaram viés negativo.

Conforme apresentado na Tabela 5.5, todas as categorias de precipitação apresentaram viés negativo. Além disso, para as faixas moderada, forte e extrema, os valores de viés são muito próximos aos valores de MAE. Esse comportamento sugere que os erros não estão distribuídos de forma simétrica entre superestimativas e subestimativas, mas são predominantemente associados à previsão de valores inferiores aos observados.

Uma possível explicação para esse resultado está relacionada à baixa predominância de chuvas intensas presente no conjunto de dados. Como a maior parte das observações corresponde a chuva fraca ou ausência de precipitação, o modelo tende a privilegiar previsões mais conservadoras durante o treinamento. Consequentemente, eventos de maior intensidade, que ocorrem com menor frequência, apresentam maior dificuldade de representação e tendem a ser subestimados.

Apesar dessa limitação, os resultados demonstram a viabilidade da utilização da arquitetura STConvS2S para o problema estudado, fornecendo uma base inicial para futuras investigações envolvendo estratégias de balanceamento, funções de perda ponderadas e maior número de épocas de treinamento.

5.6 COMPARAÇÃO ENTRE STCONVS2S E PERSISTÊNCIA

Nesta seção, o desempenho da arquitetura STConvS2S é comparado diretamente com o baseline de persistência. Essa comparação foi realizada sobre o mesmo conjunto de teste, utilizando os mesmos horizontes de previsão, estações e métricas de avaliação. O Random Forest local, apresentado anteriormente como experimento preliminar de calibração local, não é incluído nesta comparação quantitativa direta, pois foi avaliado em uma configuração experimental diferente, restrita a um conjunto reduzido de estações e com formulação pontual.

A Tabela 5.6 apresenta a comparação global entre a persistência e a STConvS2S. Observa-se que, na avaliação global, a arquitetura espaço-temporal apresentou menores valores de RMSE e MAE em relação ao baseline de persistência, indicando melhor desempenho médio no conjunto de teste. Entretanto, esse resultado não se mantém de forma uniforme em todos os regimes de precipitação, sendo necessária também a análise estratificada por intensidade. Além disso, a persistência apresentou viés global mais próximo de zero, enquanto a STConvS2S apresentou viés negativo mais acentuado, indicando tendência de subestimativa.

Além da avaliação global, também foi realizada a comparação por horizonte de previsão. A Tabela 5.7 apresenta os resultados da persistência e da STConvS2S para os

Tabela 5.6: Comparação global entre persistência e STConvS2S no conjunto de teste.

Modelo	RMSE	MAE	Viés
Persistência	0.5790	0.0642	-0.0012
STConvS2S	0.1533	0.0429	-0.0423

cinco passos futuros avaliados. Nota-se que a persistência apresenta aumento progressivo do erro à medida que o horizonte de previsão cresce, comportamento esperado para uma abordagem que apenas replica a condição observada no instante atual. Já a STConvS2S mantém erros mais estáveis ao longo dos horizontes.

Tabela 5.7: Comparação entre persistência e STConvS2S por horizonte de previsão.

Modelo	Horizonte	RMSE	MAE	Viés
Persistência	T+1	0.4624	0.0460	-0.0024
Persistência	T+2	0.5500	0.0608	-0.0017
Persistência	T+3	0.5995	0.0677	-0.0009
Persistência	T+4	0.6162	0.0719	-0.0006
Persistência	T+5	0.6492	0.0746	-0.0002
STConvS2S	T+1	0.1416	0.0439	-0.0434
STConvS2S	T+2	0.1360	0.0433	-0.0430
STConvS2S	T+3	0.1372	0.0426	-0.0421
STConvS2S	T+4	0.1339	0.0426	-0.0419
STConvS2S	T+5	0.1364	0.0422	-0.0413

Por fim, a Tabela 5.8 apresenta a comparação por faixa de intensidade de precipitação. Os resultados indicam que a STConvS2S apresenta melhor desempenho na faixa de chuva fraca. Na classe de chuva moderada, observa-se redução do RMSE em relação à persistência, porém com aumento do MAE e maior viés negativo. Já nas faixas de chuva forte e extrema, a persistência apresentou menores erros, evidenciando que a arquitetura ainda apresenta dificuldade em representar eventos severos.

De modo geral, os resultados mostram que a arquitetura STConvS2S apresentou melhor desempenho global que a persistência, principalmente devido aos ganhos obtidos nas situações de chuva fraca, que representam a maior parte das observações do conjunto de teste. Entretanto, a análise por intensidade evidencia que esse comportamento não se estende aos eventos de maior severidade. Nas faixas de chuva forte e extrema, a persistência apresentou menores erros e menor viés absoluto, indicando que esses eventos ainda representam um desafio para a arquitetura proposta.

Tabela 5.8: Comparação entre persistência e STConvS2S por faixa de intensidade de precipitação.

Modelo	Faixa	RMSE	MAE	Viés
Persistência	Fraca	0.3490	0.0377	0.0166
Persistência	Moderada	3.0458	2.0767	-1.0586
Persistência	Forte	7.9954	7.2761	-5.8119
Persistência	Extrema	16.5619	15.0947	-14.4031
STConvS2S	Fraca	0.1148	0.0219	-0.0212
STConvS2S	Moderada	2.7701	2.4966	-2.4966
STConvS2S	Forte	8.8016	8.6281	-8.6281
STConvS2S	Extrema	18.7495	17.9092	-17.9092

5.7 VISUALIZAÇÃO ESPACIAL DAS ESTIMATIVAS

A avaliação da abordagem de calibração local foi complementada por uma análise espacial das estimativas de precipitação, com o objetivo de verificar qualitativamente se o Random Forest local é capaz de estimar campos de precipitação espacialmente coerentes com os sistemas precipitantes observados pelo radar. Para isso, foram gerados mapas de precipitação estimada utilizando as variáveis de refletividade e elevação, aplicados diretamente às imagens do Radar Meteorológico do Sumaré. Para fins de visualização e comparação com as faixas de intensidade utilizadas na avaliação, os valores estimados foram convertidos para taxa horária equivalente em (mm/h). Além disso, as localizações das estações do sistema WebSirene foram destacadas nos mapas, possibilitando a comparação direta entre a precipitação observada em superfície e a estimativa do modelo Random Forest no mesmo ponto e horário.

A Figura 5.5 apresenta um mapa da Região Metropolitana do Rio de Janeiro com a área aproximada de cobertura do Radar Meteorológico do Sumaré, destacando os principais municípios da região. O mapa foi obtido a partir do portal do sistema Alerta Rio, que disponibiliza imagens recentes do radar para acompanhamento operacional de eventos meteorológicos. A delimitação circular indicada na figura representa o alcance aproximado do radar, utilizado como referência para o monitoramento da precipitação na região. A identificação dos municípios permite contextualizar espacialmente a área de estudo e compreender melhor a localização das estações utilizadas neste trabalho.

Nas figuras de comparação apresentadas a seguir, além da visualização da refletividade do radar e do campo de precipitação estimado pelo modelo, também foi incluída a indicação da estação analisada e os valores de precipitação observada e estimada naquele ponto. Essa informação permite realizar uma comparação direta entre a medição pluviométrica registrada pela estação e o valor previsto pelo modelo no pixel correspondente, facilitando a análise do desempenho do modelo em cada situação avaliada.

A Tabela 5.9 apresenta a comparação pontual entre a precipitação medida pelas




Figura 5.5: Mapa da região do estado do Rio de Janeiro com indicação aproximada da área de cobertura do Radar Meteorológico do Sumaré (círculo tracejado). Fonte: Sistema Alerta Rio.

estações do sistema WebSirene e a precipitação estimada pelo modelo no pixel correspondente à localização de cada estação. Também são apresentados os valores RGB extraídos da imagem do radar no mesmo ponto, os quais representam a informação de refletividade utilizada como entrada do modelo. Os valores de precipitação estão expressos em taxa horária equivalente, em mm/h .

A Figura 5.6 apresenta o resultado para a Estação 10, permitindo observar a correspondência espacial entre a região de maior refletividade identificada pelo radar e a área de precipitação estimada pelo modelo. Nota-se que o modelo é capaz de identificar corretamente a presença de chuva na vizinhança da estação, embora com suavização dos valores máximos estimados.

De forma semelhante, a Figura 5.7, referente à Estação 11, evidencia que o campo de precipitação estimado acompanha o padrão espacial da refletividade observada, principalmente nas regiões associadas à chuva fraca a moderada. A comparação visual indica

Tabela 5.9: Comparação pontual entre precipitação medida, precipitação estimada e valores RGB do radar para as estações analisadas em 03/03/2019 às 19:00 UTC.

Data/Hora	Estação	RGB	Medido	Previsto
03/03/2019 19:00	10	(19, 125, 19)	0.00	2.98
03/03/2019 19:00	11	(19, 167, 19)	0.00	2.63
03/03/2019 19:00	12	(19, 167, 19)	1.60	2.56
03/03/2019 19:00	13	(11, 167, 12)	0.00	5.31
03/03/2019 19:00	14	(141, 188, 2)	0.00	2.13

boa coerência espacial entre radar e modelo nesse caso.

Na Figura 5.8, correspondente à Estação 12, observa-se novamente que o modelo reproduz a estrutura geral do sistema precipitante, identificando corretamente as áreas com ocorrência de chuva. Entretanto, em regiões com refletividade mais intensa, percebe-se maior dispersão nos valores estimados, indicando tendência à subestimação da precipitação.

A Figura 5.9 apresenta os resultados para a Estação 13 e reforça o comportamento observado nas demais estações: boa identificação das áreas com precipitação, mas com limitações na estimativa precisa da intensidade em núcleos convectivos mais intensos. A localização da estação, destacada no mapa, permite a comparação direta entre a estimativa do modelo e a medição pontual em superfície.

Por fim, a Figura 5.10 mostra o caso da Estação 14, no qual o modelo mantém coerência espacial com a refletividade observada pelo radar, sobretudo para regiões de chuva fraca. Assim como nos demais exemplos, observa-se maior incerteza associada às áreas de maior intensidade de refletividade.

Em conjunto, essas figuras demonstram que o modelo é capaz de reproduzir qualitativamente a estrutura espacial dos sistemas precipitantes observados pelo radar, especialmente para eventos de baixa a moderada intensidade. Em eventos caracterizados por maior intensidade de refletividade, observou-se aumento da variabilidade espacial nas estimativas, com tendência à subestimação da precipitação em áreas de chuva forte. Esse comportamento está de acordo com os resultados quantitativos apresentados anteriormente e reflete as dificuldades do modelo em lidar com eventos raros e altamente localizados, além das limitações impostas pelo desbalanceamento do conjunto de dados.

Dessa forma, a análise espacial reforça que, embora o modelo apresente limitações na estimativa precisa de eventos extremos, ele é capaz de reproduzir de maneira coerente a estrutura espacial dos sistemas precipitantes, o que representa um resultado relevante para aplicações de monitoramento e nowcasting de precipitação.




Figura 5.6: Comparação entre a imagem de refletividade do radar (RGB, refletividade máxima) e a precipitação estimada pelo modelo Random Forest (RGB + relevo), expressa em mm/h equivalente, para a Estação 10 em 03/03/2019 às 19:00 UTC. O ponto branco indica a localização da estação.

5.8 DISCUSSÃO DOS RESULTADOS

Os resultados obtidos neste trabalho indicam que a arquitetura STConvS2S é uma abordagem viável para a previsão imediata de precipitação a partir de sequências de imagens do Radar Meteorológico do Sumaré e medições pluviométricas do sistema WebSirene. A comparação com o baseline de persistência mostrou que o modelo espaço-temporal apresentou menores valores globais de RMSE e MAE, sugerindo que o uso de sequências de radar agrega informação na avaliação global do conjunto de teste, sobretudo para os eventos de baixa intensidade, que predominam na base de dados.

Apesar do bom desempenho global, a análise por faixas de intensidade evidenciou limitações importantes. A STConvS2S apresentou melhor desempenho nos eventos de baixa intensidade, mas teve maior dificuldade em representar precipitações moderadas, fortes e extremas. Nessas faixas, observou-se viés negativo mais acentuado, indicando tendência de subestimativa da precipitação. Esse comportamento está diretamente relacionado ao forte desbalanceamento natural dos dados, nos quais a maior parte das observações corresponde à ausência de chuva ou chuva fraca, enquanto eventos severos ocorrem com frequência muito menor.

A comparação com a persistência reforça essa interpretação. Embora a STConvS2S tenha apresentado menos erros na avaliação global, a persistência foi competitiva e, em algumas faixas de maior intensidade, apresentou desempenho superior, especialmente nos eventos fortes e extremos. Isso indica que a arquitetura treinada ainda não conseguiu representar adequadamente os padrões associados a eventos raros e intensos, possivelmente devido ao número limitado de épocas de treinamento, à função de perda não ponderada por intensidade e à baixa frequência desses casos no conjunto de dados.

O experimento preliminar com Random Forest local também contribui para essa




Figura 5.7: Comparação entre a imagem de refletividade do radar (RGB, refletividade máxima) e a precipitação estimada pelo modelo Random Forest (RGB + relevo), expressa em mm/h equivalente, para a Estação 11 em 03/03/2019 às 19:00 UTC. O ponto branco indica a localização da estação.

discussão, embora seus resultados não sejam diretamente comparáveis aos da STConvS2S. Por ter sido conduzido em uma configuração pontual, restrita a cinco estações e baseada em atributos extraídos do pixel correspondente a cada estação, esse experimento evidencia as limitações de abordagens locais, que não exploram explicitamente a estrutura espacial completa nem a evolução temporal dos sistemas precipitantes. A análise com Random Forest indicou dificuldade em explicar a variabilidade total da precipitação e tendência de subestimativa em eventos mais intensos, comportamento também observado na avaliação da STConvS2S.

A utilização de alvos esparsos e máscaras de observação foi uma etapa importante da metodologia, pois permitiu treinar a arquitetura utilizando apenas medições pluviométricas reais, sem necessidade de interpolar artificialmente a precipitação para toda a grade espacial. No entanto, essa estratégia resolve o problema da ausência de observações em todos os pixels, mas não elimina o desbalanceamento entre eventos fracos e intensos. Assim, embora o modelo produza estimativas para toda a grade, a supervisão efetiva continua concentrada nos pontos onde existem estações WebSirene.

De forma geral, os resultados mostram que a modelagem espaço-temporal apresentou melhor desempenho na avaliação global do conjunto de teste. Porém, essa avaliação agregada deve ser interpretada com cautela, pois é fortemente influenciada pela predominância de eventos de chuva fraca na base de dados. Por esse motivo, a análise estratificada por intensidade é essencial para revelar limitações que ficam mascaradas nas métricas globais, especialmente nos eventos moderados, fortes e extremos. Esses resultados demonstram o potencial da STConvS2S para aplicações de *nowcasting* baseadas em radar, ao mesmo tempo em que evidenciam a necessidade de investigar estratégias de balanceamento, funções de perda ponderadas por intensidade, maior número de épocas de




Figura 5.8: Comparação entre a imagem de refletividade do radar (RGB, refletividade máxima) e a precipitação estimada pelo modelo Random Forest (RGB + relevo), expressa em mm/h equivalente, para a Estação 12 em 03/03/2019 às 19:00 UTC. O ponto branco indica a localização da estação.

treinamento e inclusão de variáveis auxiliares para melhorar a representação de eventos de precipitação intensa.




Figura 5.9: Comparação entre a imagem de refletividade do radar (RGB, refletividade máxima) e a precipitação estimada pelo modelo Random Forest (RGB + relevo), expressa em mm/h equivalente, para a Estação 13 em 03/03/2019 às 19:00 UTC. O ponto branco indica a localização da estação.




Figura 5.10: Comparação entre a imagem de refletividade do radar (RGB, refletividade máxima) e a precipitação estimada pelo modelo Random Forest (RGB + relevo), expressa em mm/h equivalente, para a Estação 14 em 03/03/2019 às 19:00 UTC. O ponto branco indica a localização da estação.

6 CONCLUSÃO

6.1 ANÁLISE RETROSPECTIVA

Este trabalho teve como objetivo construir e avaliar um modelo espaço-temporal para previsão imediata de precipitação na Região Metropolitana do Rio de Janeiro, utilizando imagens do Radar Meteorológico do Sumaré e medições pluviométricas do sistema WebSirene. Para isso, foi adotada a arquitetura STConvS2S, em sua configuração STConvS2S-C, treinada com sequências de imagens de radar como entrada e campos futuros de precipitação como saída.

A metodologia desenvolvida permitiu integrar dados de radar e estações de superfície em uma estrutura compatível com modelos sequência-para-sequência. As imagens do radar foram agregadas em intervalos de 15 minutos, redimensionadas para uma grade regular de 256×256 pixels e organizadas em sequências temporais. Como as medições pluviométricas estão disponíveis apenas nos pontos onde existem estações, foram construídos alvos esparsos de precipitação e máscaras de observação, permitindo que a função de perda fosse calculada apenas nos pixels com observações reais.

Os resultados obtidos indicaram que a arquitetura STConvS2S apresenta potencial para o problema de *nowcasting* de precipitação, por permitir o uso explícito da evolução temporal das imagens de radar. Na avaliação global, o modelo apresentou menores valores de RMSE e MAE em relação ao baseline de persistência. No entanto, essa interpretação deve ser feita com cautela, pois as métricas globais são fortemente influenciadas pela predominância de eventos de chuva fraca no conjunto de teste.

A análise estratificada por intensidade revelou limitações importantes. O modelo apresentou maior dificuldade na previsão de eventos moderados, fortes e extremos, com tendência à subestimativa da precipitação. Nessas faixas, a persistência permaneceu competitiva ou apresentou desempenho superior, evidenciando que os eventos severos ainda representam um desafio em aberto para a abordagem avaliada.

De forma geral, o trabalho permitiu consolidar um pipeline completo para preparação dos dados, construção de alvos mascarados, treinamento da arquitetura espaço-temporal e avaliação quantitativa e qualitativa das previsões. Assim, mesmo com limitações, a abordagem desenvolvida representa uma base experimental relevante para o avanço de métodos de *nowcasting* baseados em radar e aprendizado profundo no contexto do projeto RioNowCast.

6.2 TRABALHOS FUTUROS

Como trabalhos futuros, recomenda-se investigar estratégias que aumentem a capacidade do modelo em representar eventos de precipitação moderada, forte e extrema, uma vez que esses fenômenos ocorrem com baixa frequência e apresentam maior dificul-

dade de previsão. Entre as possibilidades estão o emprego de funções de perda ponderadas, técnicas de balanceamento dos dados e estratégias de amostragem voltadas para eventos de maior intensidade.

Também é recomendada a realização de experimentos com diferentes configurações de hiperparâmetros, maior número de épocas de treinamento e arquiteturas alternativas de aprendizado profundo voltadas para previsão espaço-temporal, permitindo avaliar o impacto dessas modificações no desempenho do modelo.

Outra perspectiva consiste na incorporação de fontes adicionais de informação, como produtos de satélite, variáveis atmosféricas provenientes de modelos numéricos ou índices de instabilidade, visando fornecer contexto meteorológico complementar às imagens de radar e, conseqüentemente, melhorar a capacidade preditiva do modelo.

Por fim, sugere-se ampliar a avaliação operacional do modelo, considerando diferentes eventos meteorológicos, horizontes de previsão e critérios de desempenho voltados a sistemas de alerta. Essa etapa é fundamental para aproximar a metodologia proposta de aplicações reais de monitoramento e apoio à tomada de decisão em eventos de chuva intensa na Região Metropolitana do Rio de Janeiro.

REFERÊNCIAS

- AlertaRio ALERTARIO, C. de Operações da Prefeitura do Rio de J. **Sistema Alerta Rio**. Disponível em: <https://www.sistema-alerta-rio.com.br/>.
- Ayoade 1996 AYOADE, J. O. **Introdução à Climatologia para os Trópicos**. Editora Bertrand Brasil S.A., 1996. ISBN 85-286-0427-6. Disponível em: https://www2.ifmg.edu.br/governadorvaladares/pesquisa/laboratorio-de-climatologia/livros/ayoad-j-o-_introducao_a_climatologia_para_os_tropicos.pdf.
- Barella 2015 BARELLA, V. H. **Técnicas para o Problema de Dados Desbalanceados em Classificação Hierárquica**. Dissertação (Mestrado) — Universidade de São Paulo – Instituto de Ciências Matemáticas e de Computação, 2015. Disponível em: https://teses.usp.br/teses/disponiveis/55/55134/tde-06012016-145045/publico/VictorHugoBarella_dissertacao_revisada.pdf.
- Bechini e Chandrasekar 2017 BECHINI, R.; CHANDRASEKAR, V. An enhanced optical flow technique for radar nowcasting of precipitation and winds. **Journal of Atmospheric and Oceanic Technology**, v. 34, n. 12, 12 2017. Disponível em: <https://journals.ametsoc.org/view/journals/atot/34/12/jtech-d-17-0110.1.xml>.
- Berne e Krajewski 2013 BERNE, A.; KRAJEWSKI, W. Radar for hydrology: Unfulfilled promise or unrecognized potential? **Advances in Water Resources**, v. 51, 2013. Disponível em: <https://doi.org/10.1016/j.advwatres.2012.05.005>.
- Byun e Cha 2025 BYUN, J.; CHA, J. Enhancing rainfall prediction accuracy through image fusion of radar and numerical weather prediction models. **Expert Systems with Applications**, v. 303, 2025. Disponível em: <https://doi.org/10.1016/j.eswa.2025.130516>.
- Caseri, Santos e Stephany 2022 CASERI, A.; SANTOS, L.; STEPHANY, S. A convolutional recurrent neural network for strong convective rainfall nowcasting using weather radar data in southeastern brazil. **Artificial Intelligence in Geosciences**, v. 3, 2022. Disponível em: <https://doi.org/10.1016/j.aiig.2022.06.001>.
- Castro et al. 2021 CASTRO, R. et al. Stconvs2s: Spatiotemporal convolutional sequence to sequence network for weather forecasting. **Neurocomputing**, v. 426, p. 285–298, 2021. ISSN 0925-2312. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0925231220315794>.
- Coelho e Nunes 2020 COELHO, L. A. F.; NUNES, A. B. Eventos recentes de chuva intensa na cidade do rio de janeiro: Análise sinótica. **Revista Brasileira de Geografia Física**, v. 13, 2020. Disponível em: <https://doi.org/10.26848/rbgf.v13.3.p994-1012>.
- Collier 1986 COLLIER, C. Accuracy of rainfall estimates by radar, part i: Calibration by telemetering raingauges. **Journal of Hydrology**, v. 83, 1986. Disponível em: [https://doi.org/10.1016/0022-1694\(86\)90152-6](https://doi.org/10.1016/0022-1694(86)90152-6).
- Defesa Civil do Município do Rio de Janeiro 2020 Defesa Civil do Município do Rio de Janeiro. **Plano de Contingência Municipal para Chuvas Intensas: Tático-Operacional**. [S.l.], 2020. Disponível em: https://www.defesacivil.rj.gov.br/images/planos_de_contingencias/Plano-de-Contingencia-Municipal---Chuvas-Intensas---Ttico-Operacional-revisado-em-22-12-2020.pdf.

- Elreedy, Atiya e Kamalov 2023 ELREEDY, D.; ATIYA, A. F.; KAMALOV, F. A theoretical distribution analysis of synthetic minority oversampling technique (smote) for imbalanced learning. **Machine Learning**, Springer, v. 113, 1 2023. Disponível em: <https://link.springer.com/article/10.1007/s10994-022-06296-4>.
- Germann e Zawadzki 2002 GERMAN, U.; ZAWADZKI, I. The motion and evolution of precipitation systems. **Atmospheric Research**, v. 61, n. 1, 12 2002. Disponível em: https://journals.ametsoc.org/view/journals/mwre/130/12/1520-0493_2002_130_2859_sdotpo_2.0.co_2.xml.
- Green 2024 GREEN, A. C. A framework for space-time modelling of rainfall events for hydrological applications of weather radar. **Journal of Hydrology**, 2024. Disponível em: <https://doi.org/10.1016/j.jhydrol.2024.130630>.
- Huang et al. 2019 HUANG, W. et al. Classified early-warning and nowcasting of hail weather based on radar products and random forest algorithm. **IEEE**, 12 2019. Disponível em: <https://ieeexplore.ieee.org/document/9026039>.
- Kim, Kwon e Kim 2021 KIM, T.-J.; KWON, H.-H.; KIM, K. B. Calibration of the reflectivity-rainfall rate (z-r) relationship using long-term radar reflectivity factor over the entire south korea region in a bayesian perspective. **Journal of Hydrology**, v. 593, 2021. Disponível em: <https://doi.org/10.1016/j.jhydrol.2020.125790>.
- Knippelberg 2019 KNIPPELBERG, F. d. M. Estações meteorológicas: funcionamento e a sua importância na agricultura. **Universidade Federal de Mato Grosso**, 2019. Disponível em: https://evento.ufmt.br/download/sub_fd6e78251792ea16591cd8ca2c063ba1.pdf.
- Krawczyk 2016 KRAWCZYK, B. Learning from imbalanced data: open challenges and future directions. **Progress in Artificial Intelligence**, Springer, v. 5, 4 2016. Disponível em: <https://link.springer.com/article/10.1007/s13748-016-0094-0>.
- Liu et al. 2025 LIU, D. et al. A deep learning-based precipitation nowcasting model fusing gnss-pwv and radar echo observations. **Atmospheric and Oceanic Technology**, IEEE, 3 2025. Disponível em: <https://ieeexplore.ieee.org/document/10942428>.
- Lukach Thomas Dally et al. 2022 LUKACH THOMAS DALLY, W. E. M. et al. The development of an unsupervised hierarchical clustering analysis of dual-polarization weather surveillance radar observations to assess nocturnal insect abundance and diversity. **Remote Sensing in Ecology and Conservation**, 4 2022. Disponível em: <https://www.researchgate.net/publication/360839176>.
- Nanding, Ramirez e Han 2021 NANDING, N.; RAMIREZ, M.; HAN, D. Uncertainty assessment of radar-raingauge merged rainfall estimates in river discharge simulations. **Journal of Hydrology**, v. 603, 2021. Disponível em: <https://doi.org/10.1016/j.jhydrol.2021.127093>.
- Ouallouche, Lazri e Ameer 2018 OUALLOUCHE, F.; LAZRI, M.; AMEUR, S. Improvement of rainfall estimation from msg data using random forests classification and regression. **Atmospheric Research**, v. 211, 2018. Disponível em: <https://doi.org/10.1016/j.atmosres.2018.05.001>.

Santos, Cunha e Ribeiro-Neto 2019 SANTOS, S. R. Q. d.; CUNHA, A. P. M. d. A.; RIBEIRO-NETO, G. G. Avaliação de dados de precipitação para o monitoramento do padrão espaço-temporal da seca no nordeste do brasil. **Associação Brasileira de Climatologia**, v. 25, 2019. Disponível em: <https://revistas.ufpr.br/revistaabclima/article/view/62018>.

Sirtoli, Cruz e Mantovani 2008 SIRTOLI, A.; CRUZ, C.; MANTOVANI, L. Atributos do relevo derivados de modelo digital de elevação e suas relações com solos. **Scientia Agraria**, v. 9, 2008. Disponível em: <https://doi.org/10.5380/rsa.v9i3.11517>.

Tosiri et al. 2021 TOSIRI, W. et al. Precipitation nowcasting using deep learning on radar data augmented with satellite data. 7 2021. Disponível em: <https://dl.acm.org/doi/10.1145/3468784.3470469>.

Wang et al. 2017 WANG, Y. et al. **Guidelines for Nowcasting Techniques**. [s.n.], 2017. ISBN 978-92-63-11198-2. Disponível em: <https://library.wmo.int/records/item/55666-guidelines-for-nowcasting-techniques>.

Wang et al. 2022 WANG, Z. et al. Relative importance of radar variables for nowcasting heavy rainfall: A machine learning approach. **IEEE Transactions on Geoscience and Remote Sensing**, v. 61, 12 2022. Disponível em: <https://ieeexplore.ieee.org/document/9994767>.

**APÊNDICE A – DETALHAMENTO DAS ESTAÇÕES DO
SISTEMA WEBSIRENE**

Este apêndice apresenta informações complementares sobre as estações do sistema WebSirene utilizadas neste trabalho. Para cada estação, são apresentados o identificador, o nome, as coordenadas geográficas e a altitude estimada a partir do Modelo Digital de Elevação utilizado na metodologia.

As coordenadas geográficas foram obtidas a partir dos metadados dos arquivos originais do WebSirene. A altitude foi extraída a partir do Modelo Digital de Elevação (DEM), considerando a localização de cada estação.

Tabela A.1: Informações das estações do sistema WebSirene utilizadas no estudo.

Estação	Nome	Latitude	Longitude	Altitude (m)
1	Adeus 1	-22.8636	-43.2636	42.0
2	Alemão 1	-22.8547	-43.2725	42.0
3	Andaraí 1	-22.9327	-43.2567	64.0
4	Baiana 1	-22.8595	-43.2657	42.0
5	Barão 1	-22.9023	-43.3434	69.0
6	Borel 2	-22.9405	-43.2531	55.0
7	Borel 3	-22.9315	-43.2515	80.0
8	Cabritos 1	-22.9647	-43.1950	87.0
9	Cachoeirinha 1	-22.9140	-43.2822	64.0
10	Cantagalo 1	-22.9808	-43.1969	80.0
11	Caracol 1	-22.8443	-43.2905	64.0
12	Cariri 1	-22.8483	-43.2805	32.0
13	Catumbi 1	-22.9214	-43.1967	17.0
14	Centro de Operações	-22.9122	-43.2038	17.0
15	Chácara do Céu 1	-22.9901	-43.2325	87.0
16	Chacrinha 1	-22.9263	-43.2196	61.0
17	Chapéu Mangueira 1	-22.9605	-43.1679	55.0
18	Comandante Luiz Souto 1	-22.9017	-43.3594	54.0
19	Cotia 1	-22.9178	-43.2817	191.0
20	Engenho da Rainha 2	-22.8711	-43.2894	39.0
21	Escondidinho 1	-22.9324	-43.2012	73.0
22	Espírito Santo 1	-22.8900	-43.3439	79.0
23	Fazenda Catete 1	-22.9250	-43.1825	63.0
24	Formiga 1	-22.9423	-43.2432	157.0
25	Guaíba 1 / Vila Pequiri	-22.8344	-43.2953	45.0
26	Guararapes 1	-22.9447	-43.2080	218.0

Continua na próxima página

Tabela A.1: Informações das estações do sistema WebSirene utilizadas no estudo.

Estação	Nome	Latitude	Longitude	Altitude (m)
27	Ignácio Dias 1	-22.9164	-43.3422	86.0
28	Jamelão 2	-22.9333	-43.2611	193.0
29	Jardim do Carmo 1	-22.8514	-43.3045	43.0
30	Joaquim de Queiroz 1	-22.8598	-43.2795	39.0
31	Julio Otoni 1	-22.9336	-43.1939	129.0
32	Juramento 2	-22.8575	-43.3130	49.0
33	Ladeira dos Tabajaras	-22.9617	-43.1880	70.0
34	Liberdade 1	-22.9266	-43.2180	135.0
35	Macacos 1	-22.9120	-43.2526	129.0
36	Mangueira 1	-22.9043	-43.2388	40.0
37	Matinha 1	-22.9255	-43.2155	54.0
38	Matriz 1	-22.9046	-43.2640	39.0
39	Mineiros 1	-22.8753	-43.3058	71.0
40	Morro da Fé 1	-22.8456	-43.2978	47.0
41	Morro do Céu 2 / Pretos Forros 1	-22.9135	-43.2942	90.0
42	Nossa Senhora da Guia 1	-22.9142	-43.2852	81.0
43	Nova Brasília 1	-22.8645	-43.2756	40.0
44	Nova Divinéia 1	-22.9295	-43.2654	98.0
45	Ocidental Fallet 1	-22.9262	-43.1918	150.0
46	Ouro Preto 2	-22.9166	-43.2979	141.0
47	Palmeiras 2	-22.8641	-43.2830	71.0
48	Parque Alvorada 2	-22.8652	-43.2805	47.0
49	Parque Candelária 1	-22.9056	-43.2341	83.0
50	Parque João Paulo II 1	-22.9291	-43.2623	68.0
51	Parque Nova Maracá 1	-22.8606	-43.3027	75.0
52	Parque Silva Vale 3	-22.8683	-43.3133	44.0
53	Parque Vila Isabel 2	-22.9159	-43.2591	41.0
54	Pavão-Pavãozinho 2	-22.9797	-43.1914	32.0
55	Piancó 2	-22.8651	-43.2586	66.0
56	Prazeres 1	-22.9340	-43.2032	196.0
57	Relicário 1	-22.8600	-43.2864	34.0
58	Rio das Pedras 2	-22.9717	-43.3319	15.0
59	Rocinha 1	-22.9896	-43.2519	46.0

Continua na próxima página

Tabela A.1: Informações das estações do sistema WebSirene utilizadas no estudo.

Estação	Nome	Latitude	Longitude	Altitude (m)
60	Rocinha 4	-22.9899	-43.2471	39.0
61	Rocinha 8	-22.9841	-43.2488	264.0
62	Rua Brício de Moraes 1	-22.8633	-43.3111	65.0
63	Rua Quiririm 2	-22.8886	-43.3569	51.0
64	Salgueiro 1	-22.9302	-43.2260	119.0
65	Santa Alexandrina 1 / Paula Ramos	-22.9357	-43.2127	111.0
66	Santa Marta 1	-22.9478	-43.1936	73.0
67	Santos Rodrigues 2 / Azevedo Lima 1	-22.9226	-43.2035	39.0
68	São Carlos 1	-22.9181	-43.2008	39.0
69	São João 2	-22.9080	-43.2667	40.0
70	São João 4	-22.9119	-43.2635	35.0
71	São Miguel Arcanjo 1	-22.8606	-43.3317	47.0
72	Sapê 1	-22.8575	-43.3330	55.0
73	Sereno 1	-22.8414	-43.2933	41.0
74	Sítio Pai João 1	-22.9911	-43.3114	7.0
75	Sumaré 1	-22.9313	-43.2169	140.0
76	Tuiuti 2 / Telégrafos	-22.8985	-43.2347	44.0
77	Unidos de Santa Tereza 3	-22.9269	-43.1994	112.0
78	Urubu 2	-22.8766	-43.3011	53.0
79	Vidigal 3	-22.9974	-43.2422	189.0
80	Vila Cabuçu 1 / Barro Preto	-22.9147	-43.2757	44.0
81	Vila Cruzeiro 1	-22.8522	-43.2783	33.0
82	Vila José de Anchieta 1	-22.8928	-43.3432	45.0
83	Vila Pereira da Silva 1	-22.9307	-43.1914	69.0